Introduction à CUDA C

Amina Guermouche

CUDA C

- Basé sur le standard C
- Extension du langage pour la programmation hétérogène
- API pour gérer les GPU, la mémoire, ...
- 3 niveaux d'abstraction : groupe de threads, mémoire partagée et une barrière de synchronisation

Fonctionnement

CPU (**Host**)

```
int main(int
argc, char
**argv)
```

GPU (**Device**)


```
__device__
ma_fonction_gpu
()
```

Fonctionnement

CPU (**Host**)

GPU (**Device**)


```
int main(int argc, char **argv)
```

```
__global__ ma_fonction_interface()
```

```
__device__ ma_fonction_gpu()
```

Fonctionnement

1. Host : Copier les données d'entrée de la mémoire du CPU à la mémoire du GPU
2. Device : Charger les instructions sur le GPU
3. Device : Copier les données vers la mémoire du CPU

Interrogation du GPU

- Quel est le nombre de GPUs disponibles
- Quelle est la taille de la mémoire disponible ?
- Quelles sont les caractéristiques des GPUs ?

```
cudaDeviceProp prop;
int count;
cudaGetDeviceCount(&count);

for (int i = 0; i < count; i ++)
{
   cudaGetDeviceProperties(&prop, i);
   printf(''Taille total de la memoire globale
        %ld\n'', prop.totalGlobalMem);
}
```

- On peut même choisir le GPU qu'on veut selon des critères ! ! ! !

```
cudaChooseDevice(&dev, &prop)
```

Exercice 1

Hello, World !

```
int main (void) {

   printf (''Hello, World!\n'');
   return 0;
}
```

- Compilation avec nvcc (compilateur NVIDIA)
- nvcc ne se plaint pas s'il n'y a pas de code pour le device

Hello, World !

```
__global__ void kernel (void){}

int main (void) {
  kernel<<<1,1>>>();
   printf (''Hello, World!\n'');
   return 0;
}
```

- Compilation avec nvcc (compilateur NVIDIA)
- nvcc ne se plaint pas s'il n'y a pas de code pour le device

Hello, World !

Code du device

```
__global__ void kernel (void)
```

- `__global__` indique que :

→ Le code s'exécute sur le device

→ Le code est appelé du host

- La partie device et interface est gérée par le compilateur nvidia
- La partie host par le compilateur C
- La syntaxe est obligatoire
- `__global__` ne retourne pas de valeur, JAMAIS

ok on utilise le GPU pour appeler la fonction kernel qui ne fait rien, super ! ! ! !

Et si on faisait faire quelque chose au GPU

```
__global__ void add (int *a, int *b, int *c){
  *c = *a + *b;
}
```

- add(...) sera appelé du host
- add(...) sera exécutée sur le device
- et la mémoire ?

Et si on faisait faire quelque chose au GPU

```
__global__ void add (int *a, int *b, int *c){
  *c = *a + *b;
}
```

- add(...) sera appelé du host
- add(...) sera exécutée sur le device
- et la mémoire ?
  - a, b, et c pointent sur la mémoire du device
  - Comment allouer de la mémoire sur le GPU ?
    `cudaMalloc()`, `cudaFree()`, `cudaMemcpy()`

Et si on faisait faire quelque chose au GPU (1/2)

```
__global__ void add (int *a, int *b, int *c){
  *c = *a + *b;
}
int main ( void ){
  int a, b, c;
  int *gpu_a, *gpu_b, *gpu_c;
  int size = sizeof(int);
```

Et si on faisait faire quelque chose au GPU (1/2)

```
__global__ void add (int *a, int *b, int *c){
  *c = *a + *b;
}
int main ( void ){
  int a, b, c;
  int *gpu_a, *gpu_b, *gpu_c;
  int size = sizeof(int);
  // allocation de l'espace pour le device
  cudaMalloc( (void **)&gpu_a, size);
  cudaMalloc( (void **)&gpu_b, size);
  cudaMalloc( (void **)&gpu_c, size);
  a=2;
  b=7;
```

Et si on faisait faire quelque chose au GPU (2/2)

```
// Copie des donnees vers le Device
  cudaMemcpy (gpu_a, &a, size,
      cudaMemcpyHostToDevice);
  cudaMemcpy (gpu_b, &b, size,
      cudaMemcpyHostToDevice);

  add <<< 1, 1 >>> (gpu_a, gpu_b, gpu_c);









  return 0
}
```

Et si on faisait faire quelque chose au GPU (2/2)

```
// Copie des donnees vers le Device
   cudaMemcpy (gpu_a, &a, size,
       cudaMemcpyHostToDevice);
   cudaMemcpy (gpu_b, &b, size,
       cudaMemcpyHostToDevice);

   add <<< 1, 1 >>> (gpu_a, gpu_b, gpu_c);

   //Copie du resultat vers Host
   cudaMemcpy (&c, gpu_c, size, cudaMemcpyDeviceToHost);









   return 0
}
```

Et si on faisait faire quelque chose au GPU (2/2)

```
// Copie des donnees vers le Device
   cudaMemcpy (gpu_a, &a, size,
       cudaMemcpyHostToDevice);
   cudaMemcpy (gpu_b, &b, size,
       cudaMemcpyHostToDevice);

   add <<< 1, 1 >>> (gpu_a, gpu_b, gpu_c);

   //Copie du resultat vers Host
   cudaMemcpy (&c, gpu_c, size, cudaMemcpyDeviceToHost);

   //Liberation de l'espace alloue
   cudaFree(gpu_a);
   cudaFree( gpu_b);
   cudaFree ( gpu_c);

   return 0
}
```

Et si on faisait faire quelque chose au GPU (2/2)

```
// Copie des donnees vers le Device
   checkCudaErrors(cudaMemcpy (gpu_a, &a, size,
       cudaMemcpyHostToDevice));
   cudaMemcpy (gpu_b, &b, size,
       cudaMemcpyHostToDevice);

   add <<< 1, 1 >>> (gpu_a, gpu_b, gpu_c);

   //Copie du resultat vers Host
   cudaMemcpy (&c, gpu_c, size, cudaMemcpyDeviceToHost);

   //Liberation de l'espace alloue
   cudaFree(gpu_a);
   cudaFree( gpu_b);
   cudaFree ( gpu_c);

   return 0
}
```

addition de 2 entiers : super utilisation du parallélisme

- Comment exécuter le code en parallèle ?

  On veut faire N fois add en parallèle

  ```
  add<<<1, 1>>> (gpu_a, gpu_b, gpu_c)
  ```

addition de 2 entiers : super utilisation du parallélisme

- Comment exécuter le code en parallèle ?

  On veut faire N fois add en parallèle

```
add<<<1, 1>>> (gpu_a, gpu_b, gpu_c)

add<<<N, 1>>> (gpu_a, gpu_b, gpu_c)
```

addition de 2 entiers : super utilisation du parallélisme

- Comment exécuter le code en parallèle ?

  On veut faire N fois add en parallèle

```
add<<<1, 1>>> (gpu_a, gpu_b, gpu_c)

add<<<N, 1>>> (gpu_a, gpu_b, gpu_c)
```

- Dans ce cas, autant faire un add sur un vecteur

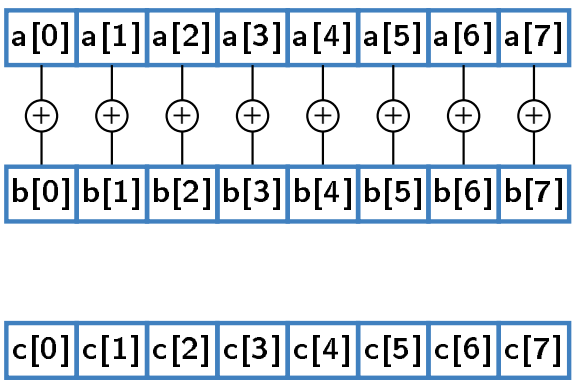

- Comment sont exprimés les indices sur le GPU ?

Programmation parallèle en CUDA

- Chaque appel parallèle à `add(...)` est appelé **block**
- L'accès à un block donné se fait via `blockIdx.x`
- Chaque `blockIdx.x` référence un élément du tableau

```
__global__ void add (int *a, int *b, int *c){
  c[blockIdx.x] = a[blockIdx.x] + b[blockIdx.x];
}
```

Programmation parallèle en CUDA

- Chaque appel parallèle à `add(...)` est appelé **block**
- L'accès à un block donné se fait via `blockIdx.x`
- Chaque `blockIdx.x` référence un élément du tableau

```
__global__ void add (int *a, int *b, int *c){
  c[blockIdx.x] = a[blockIdx.x] + b[blockIdx.x];
}
```

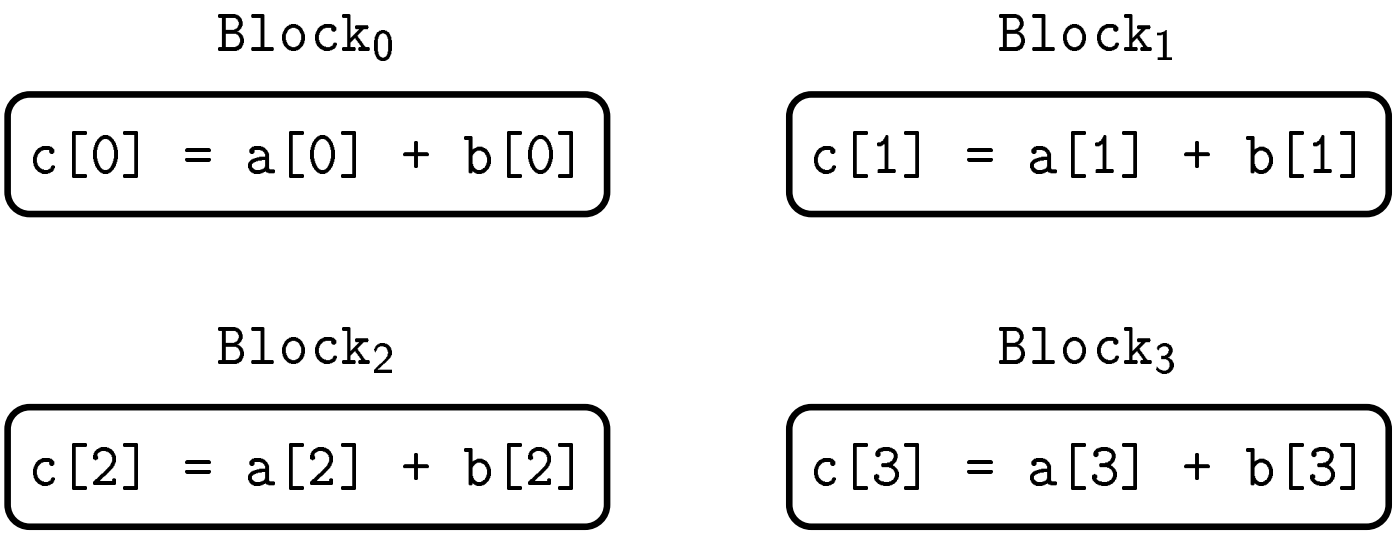

Programmation parallèle en CUDA : le main

```
#define N 512 //nombre d'elements du tableau
int main (void){
  int *a, *b, *c;
  int *gpu_a, *gpu_b, *gpu_c;
  int size = N * sizeof(int);
  // allocation de l'espace pour le device}
  cudaMalloc((void **)&gpu_a, size);
  cudaMalloc((void **)&gpu_b, size);
  cudaMalloc((void **)&gpu_c, size);

  a=(int*) malloc (size);
  b=(int*) malloc (size);
  random_ints(a, N);
  random_ints(b, N);
```

Programmation parallèle en CUDA : le main

```
// Copie des donnees vers le Device
cudaMemcpy (gpu_a,a,size,cudaMemcpyHostToDevice);
cudaMemcpy (gpu_b,b,size,cudaMemcpyHostToDevice);

add <<< N, 1 >>> (gpu_a, gpu_b, gpu_c);

//Copie du resultat
cudaMemcpy(c, gpu_c, size, cudaMemcpyDeviceToHost);

free(a); free(b); free(c);
cudaFree(gpu_a);
cudaFree(gpu_b);
cudaFree(gpu_c);
return 0;
}
```

Et si on avait un vecteur à 2 dimensions (une matrice donc) ?

- Le nombre de blocks lancés représentent une grille (*grid*)
- Le nombre de blocks par dimension est limité (`maxGridSize[3]`)
- `blockIdx.x`, `blockIdx.y`, `blockIdx.z`
- `dim3 grid(DIM, DIM)` initialise la variable `grid` de type `dim3` qui indique la dimension de la grille (2D)
- `gridDim.x`, `gridDim.y` donnent la dimension de la grille

Grille et blocks

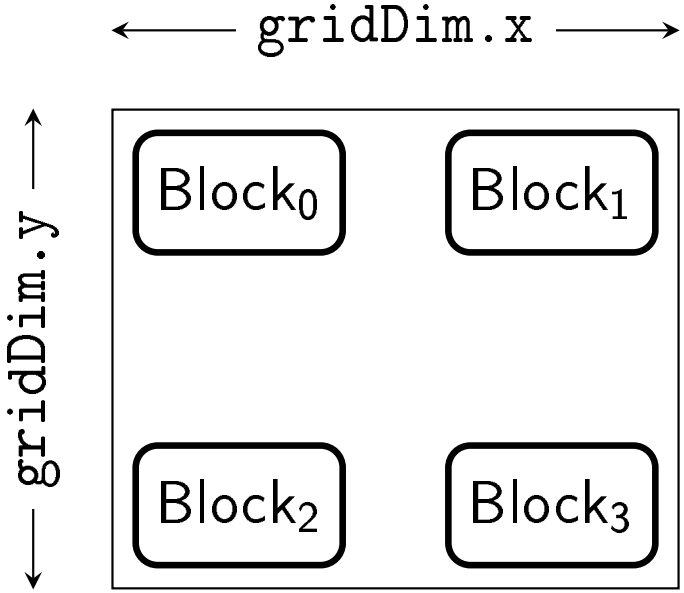

Addition de deux matrices

```
#define N 512 //taille d'une dimension de la
    matrice

__global__ void add (int *a, int *b, int *c){
  int x = blockIdx.x;
  int y = blockIdx.y;
  int indice = x + y * gridDim.x;
  c[indice] = a[indice] + b[indice];
}

int main (void){
  int *a, *b, *c;
  int *gpu_a, *gpu_b, *gpu_c;
  int size = N * sizeof(int);
  ...
  dim3 grid(N, N);
  add <<<grid, 1 >>> (dev_a, dev_b, dev_c);
  ...
}
```

Exercice 2

Threads

- Un block peut être divisé en plusieurs threads parallèles

- CUDA définit un unique id par thread `threadIdx.x`
- On utilise `threadIdx.x` au lieu de `blockIdx.x`

```
__global__ void add (int *a, int *b, int *c){
  c[threadIdx.x] = a[threadIdx.x] + b[threadIdx.x];
}
```

Programmation parallèle en CUDA : le main

```
#define N 512 //nombre d'elements du tableau
int main (void){
  int *a, *b, *c;
  int *gpu_a, *gpu_b, *gpu_c;
  int size = N * sizeof(int);
  // allocation de l'espace pour le device}
  cudaMalloc((void **)&gpu_a, size);
  cudaMalloc((void **)&gpu_b, size);
  cudaMalloc((void **)&gpu_c, size);

  a=(int*) malloc (size);
  b=(int*) malloc (size);
  random_ints(a, N);
  random_ints(b, N);
```

Programmation parallèle en CUDA : le main

```
// Copie des donnees vers le Device
cudaMemcpy (gpu_a,a,size,cudaMemcpyHostToDevice);
cudaMemcpy (gpu_b,b,size,cudaMemcpyHostToDevice);

//Lancement de l'operation avec N threads
add <<< 1, N >>> (gpu_a, gpu_b, gpu_c);

//Copie du resultat
cudaMemcpy(c, gpu_c, size, cudaMemcpyDeviceToHost);

free(a); free(b); free(c);
cudaFree(gpu_a);
cudaFree(gpu_b);
cudaFree(gpu_c);
return 0;
}
```

Des blocks et des threads

- Les threads sont numérotés de 0 à `nb_thread` par block
- `threadIdx.x` est par block

- Si on a `M` threads/block, l'indice dans un vecteur est calculé par :
  `indice = threadIdx.x + blockIdx.x * M`
- Le nombre de threads par block est donné par la variable `blockDim.x`
  `indice = threadIdx.x + blockIdx.x * blockDim.x`

add avec blocks et threads

```
#define N (2048 * 2048) //taille du tableau
#define THREAD_PER_BLOCK 512 //nombre de threads

__global__ void add (int *a, int *b, int *c){
  int indice = threadIdx.x + blockIdx.x * blockDim.
      x;
  c[indice] = a[indice] + b[indice];
}

int main (void){
  int *a, *b, *c;
  int *gpu_a, *gpu_b, *gpu_c;
  int size = N * sizeof(int);
  // allocation de l'espace pour le device}
  cudaMalloc((void **)&gpu_a, size);
  cudaMalloc((void **)&gpu_b, size);
  cudaMalloc((void **)&gpu_c, size);
```

Programmation parallèle en CUDA : le main

```
a=(int*) malloc (size);
b=(int*) malloc (size);
random_ints(a, N);
random_ints(b, N);

// Copie des donnees vers le Device
cudaMemcpy (gpu_a,a,size,cudaMemcpyHostToDevice);
cudaMemcpy (gpu_b,b,size,cudaMemcpyHostToDevice);

//Lancement de l'operation avec THREAD_PER_BLOCK
    par block
add <<< N/THREAD_PER_BLOCK,THREAD_PER_BLOCK >>>
     (gpu_a, gpu_b, gpu_c);

//Copie du resultat
cudaMemcpy(c, gpu_c, size, cudaMemcpyDeviceToHost);
```

Programmation parallèle en CUDA : le main

```
free(a); free(b); free(c);
cudaFree(gpu_a);
cudaFree(gpu_b);
cudaFree(gpu_c);
return 0;
}
```

Exercice 3

Vecteurs de taille quelconque

- Vecteur de taille non multiple de `blockDim.x`

```
__global__ void add (int *a, int *b, int *c,
    int n){
  int indice = threadIdx.x + blockIdx.x *
      blockDim.x;
  if (indice < n)
      c[indice] = a[indice] + b[indice];
}
```

- Au niveau du main

```
add <<< (N+THREAD_PER_BLOCK-1)/
    THREAD_PER_BLOCK, THREAD_PER_BLOCK >>> (
    gpu_a, gpu_b, gpu_c, N);
```

Des blocks et des threads

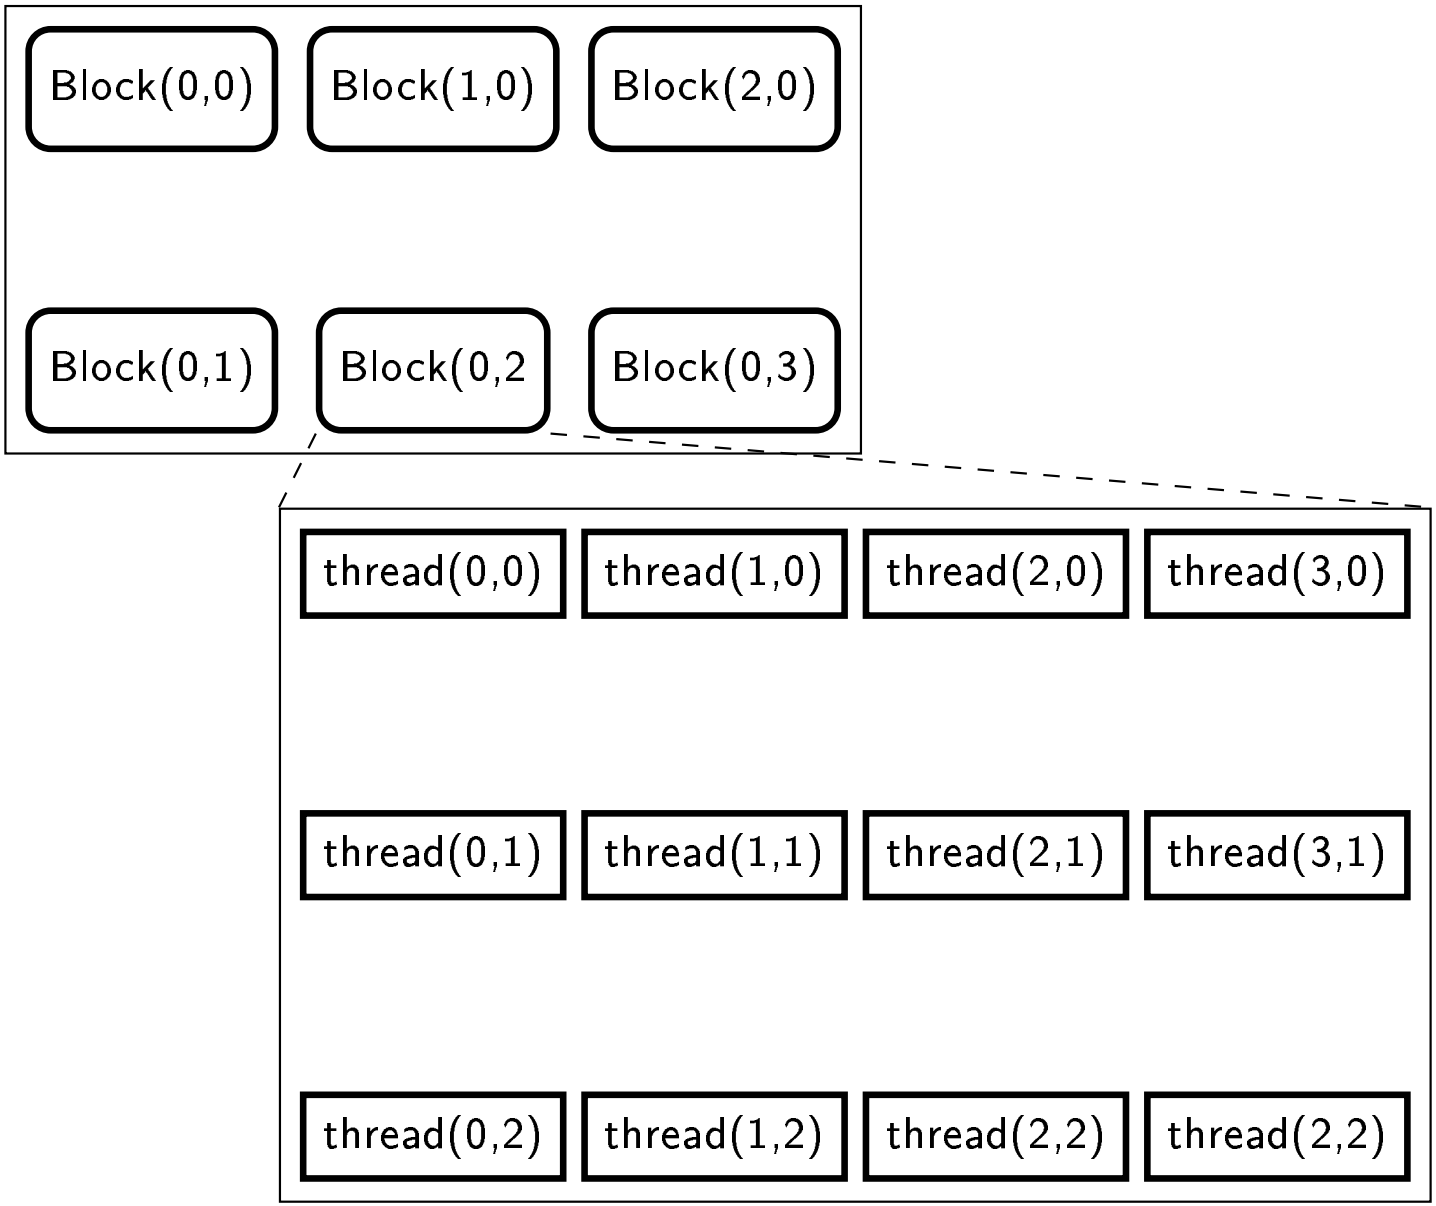

Des blocks et des threads

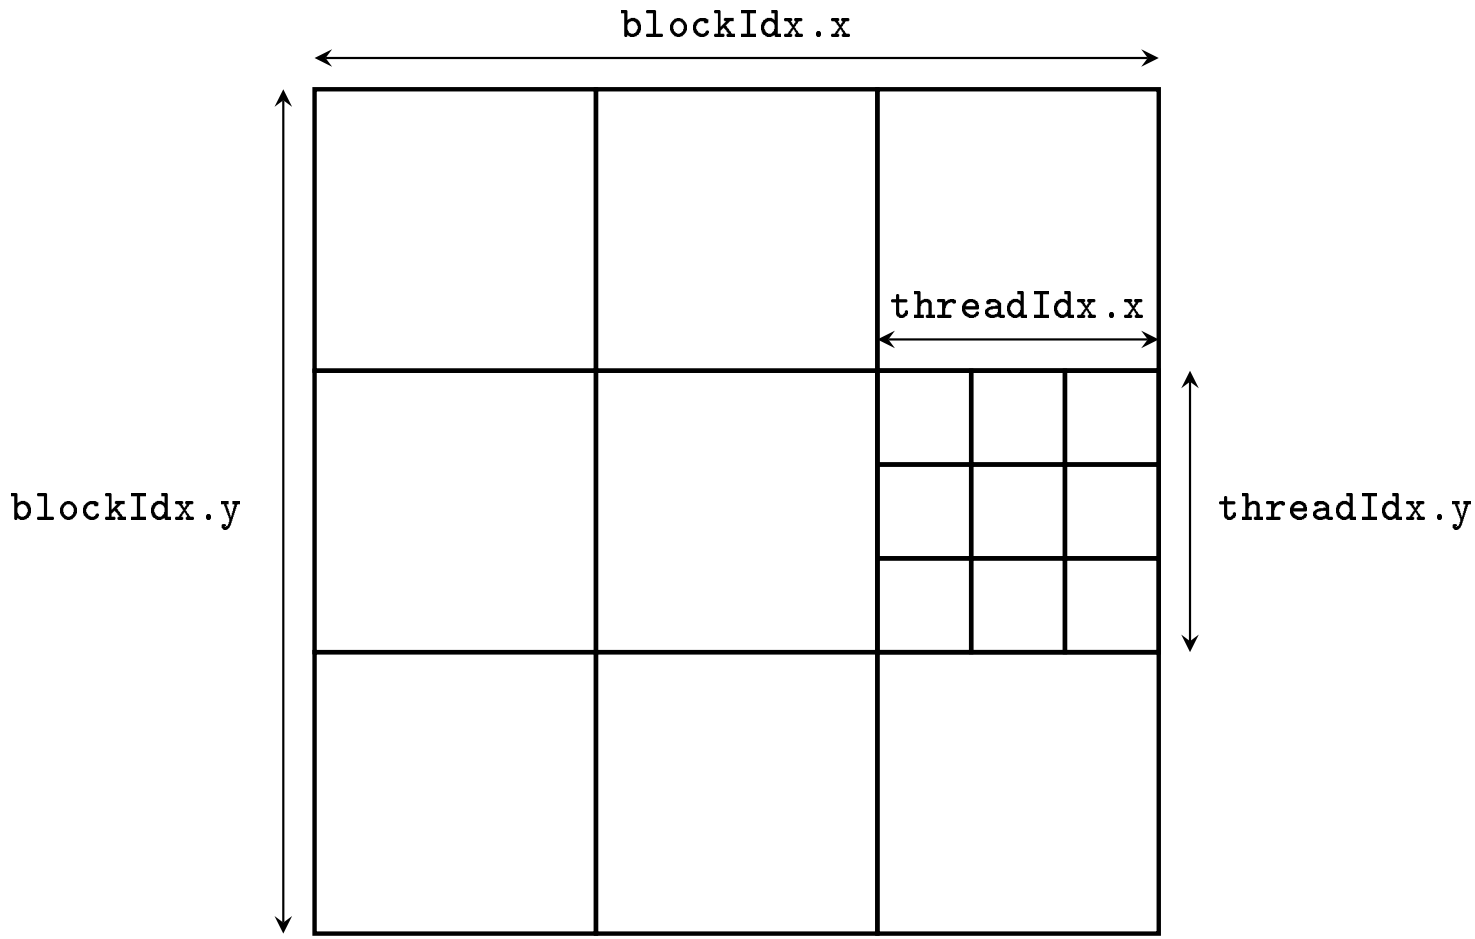

Des blocks et des threads

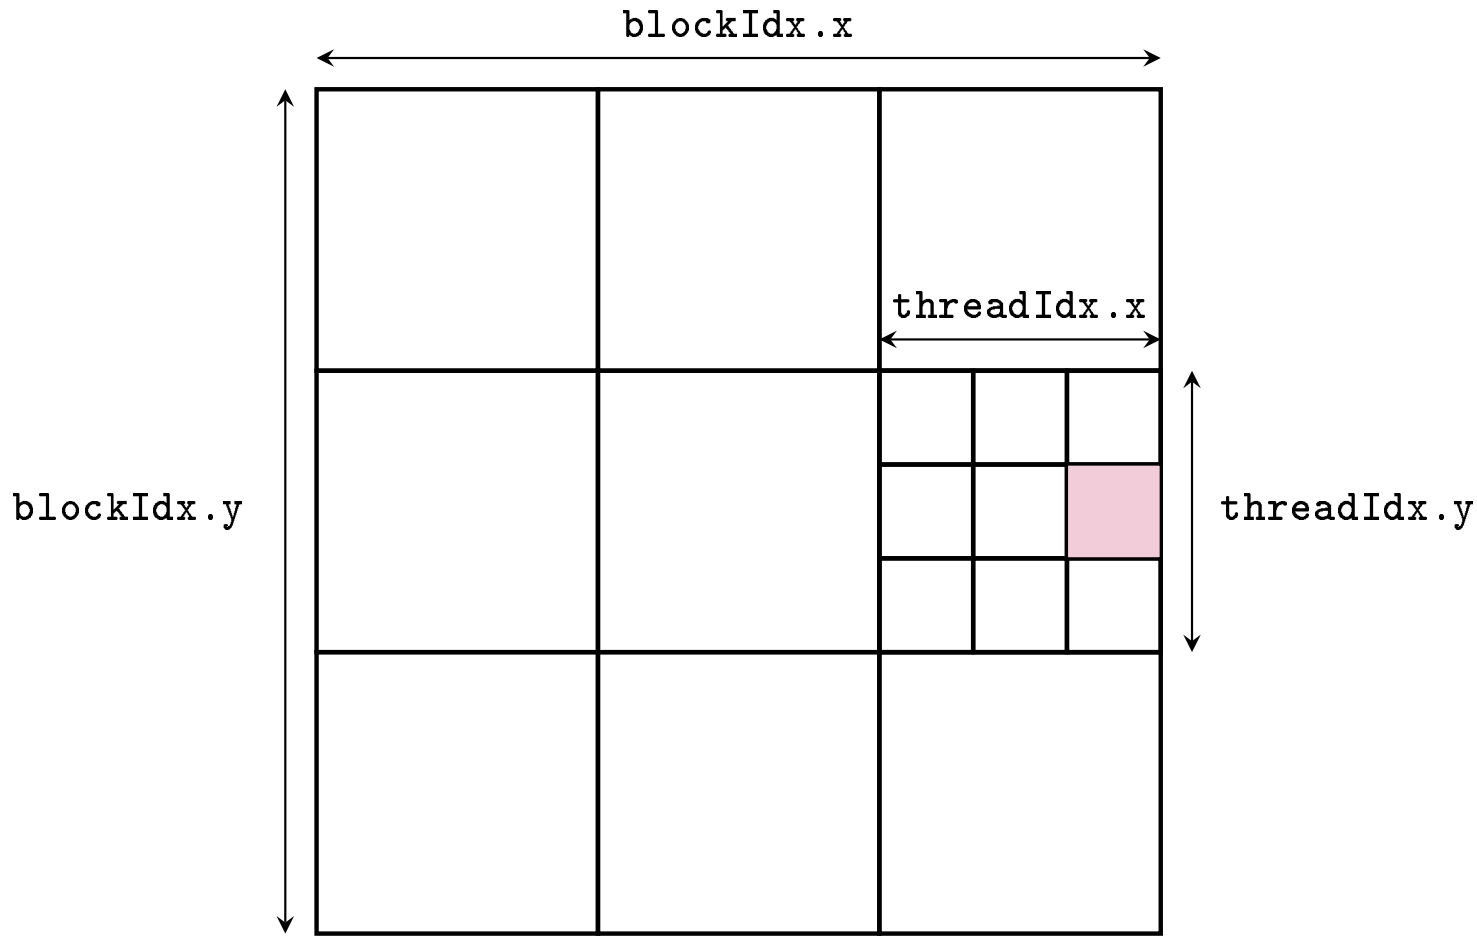

Des blocks et des threads

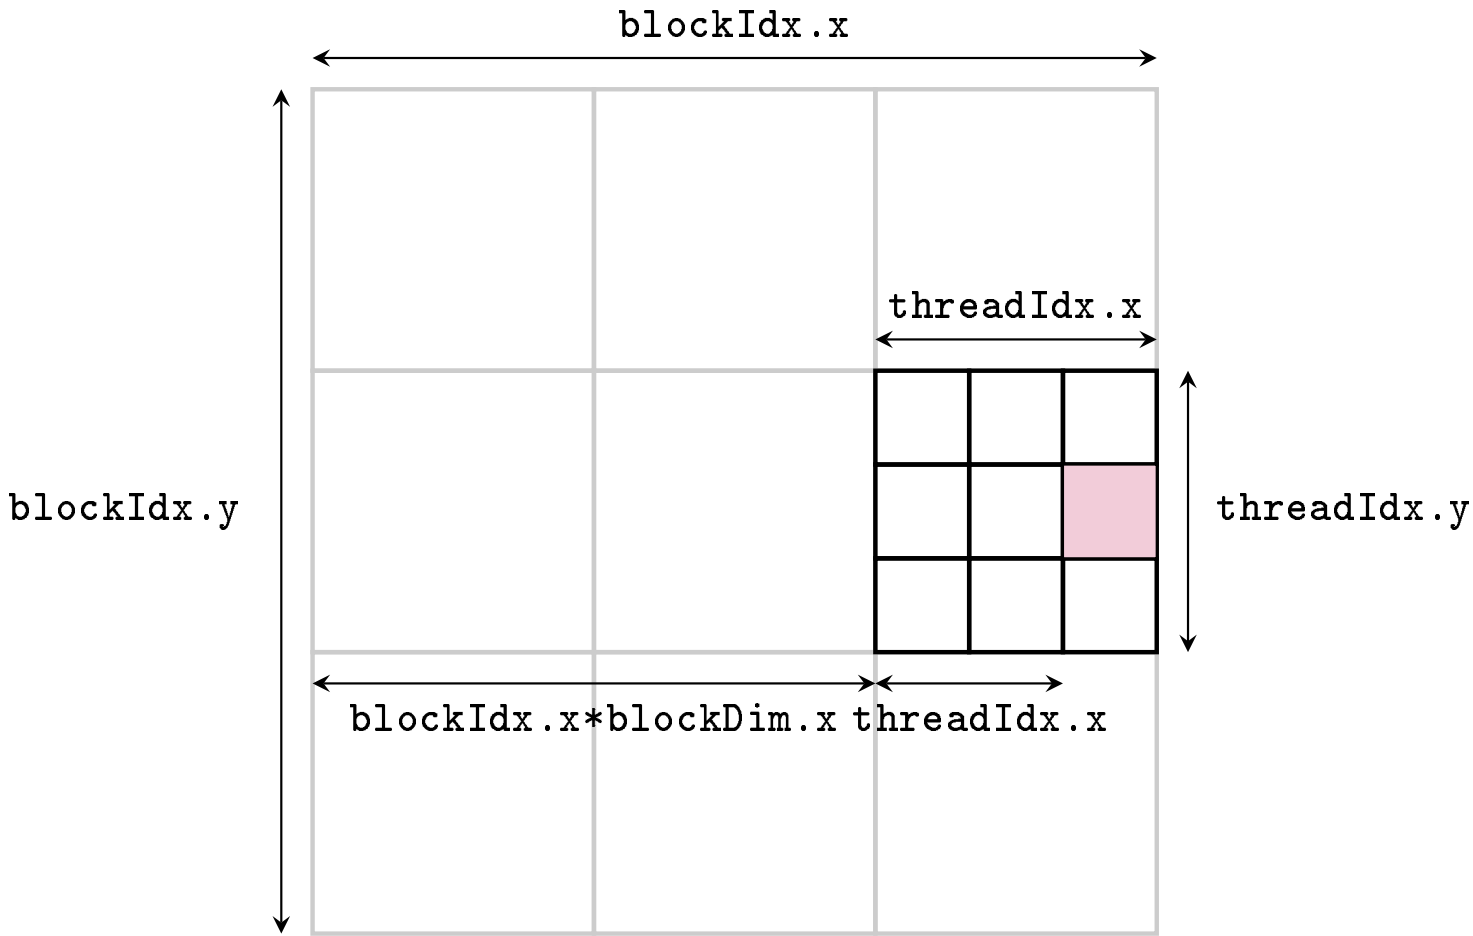

Des blocks et des threads

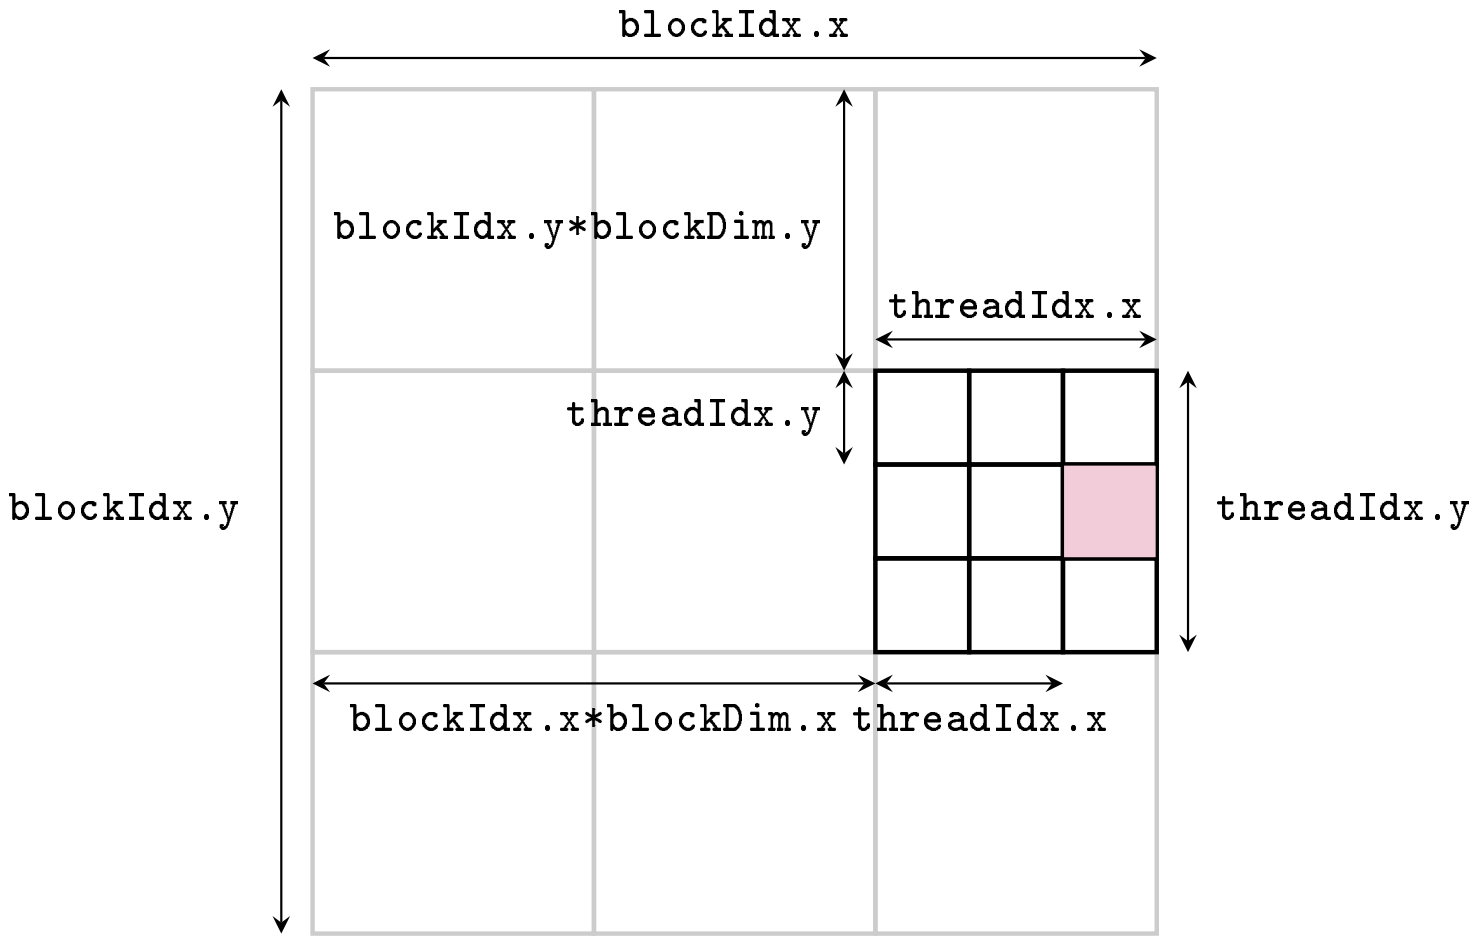

Addition de 2 matrices

- `colonne = blockIdx.x*blockDim.x+theadIdx.x`
- `ligne = blockIdx.y*blockDim.y+theadIdx.y`

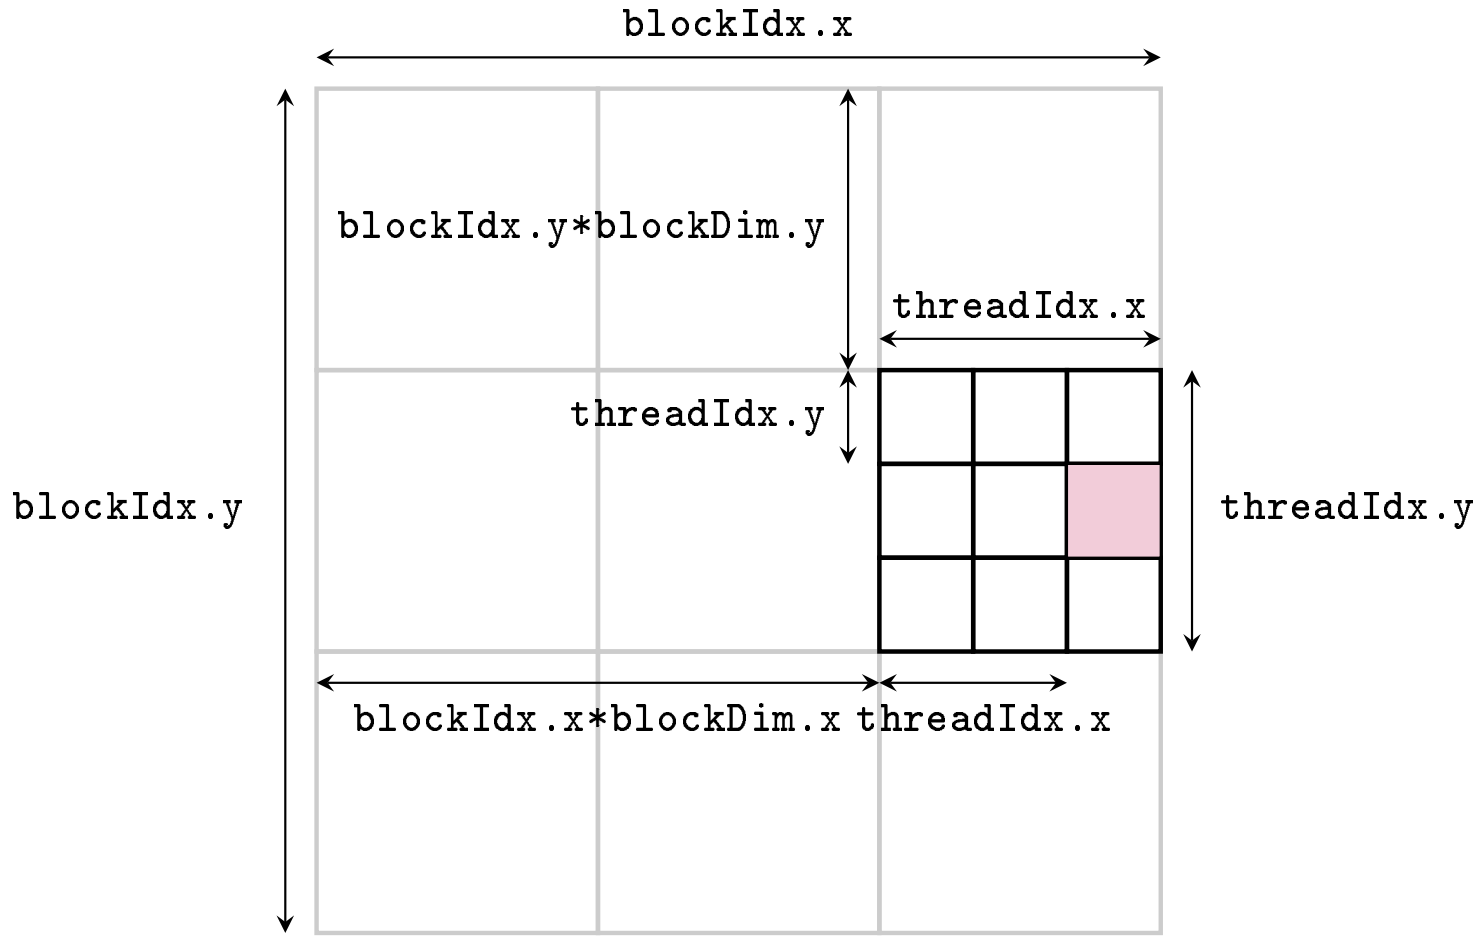

Addition de deux matrices

```
#define N 2048 //taille de la matrice
#define THREAD_PER_BLOCK 512 //nombre de threads

__global__ void add (int *a, int *b, int *c){
  int colonne = blockIdx.x*blockDim.x+theadIdx.x;
  int ligne = blockIdx.y*blockDim.y+theadIdx.y;
  int indice = ligne * N + colonne;
  // N = gridDim.x * blockDim.x;
  c[indice] = a[indice] + b[indice];
}

int main (int argc, char** argv)
{
  ...
  dim3 block(THREAD_PER_BLOCK, THREAD_PER_BLOCK);
  dim3 grid(N/blockDim.x, N/blockDim.y);
  add <<<grid, block >>> (dev_a, dev_b, dev_c);
  ...
}
```

Pourquoi s'embêter avec des threads et des blocks ?

- 1 thread = 1 coeur
- 1 block = 1SM
- 1 block est exécuté sur 1SM
- Blocks :
  - Les blocks sont exécutés dans n'importe quel ordre, séquentiellement ou en parallèle
  - L'avantage est que ça scale automatiquement avec le nombre de SM

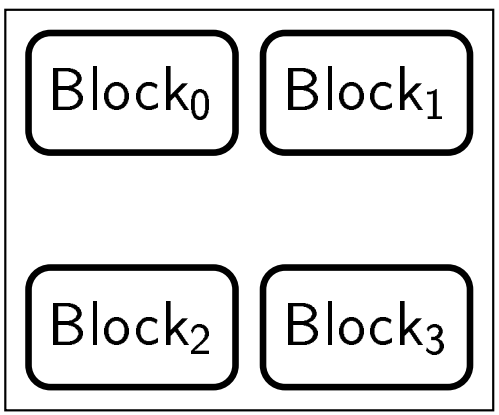

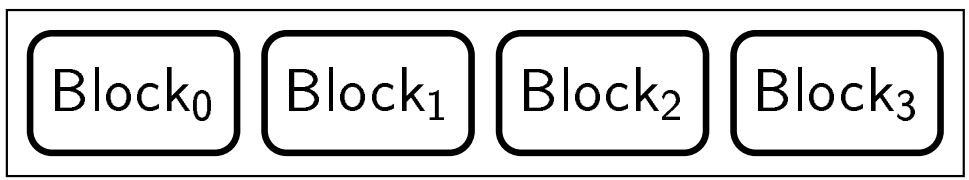

Pourquoi s'embêter avec des threads et des blocks ?

- 1 thread = 1 coeur
- 1 block = 1SM
- 1 block est exécuté sur 1SM
- Blocks :
  - Les blocks sont exécutés dans n'importe quel ordre, séquentiellement ou en parallèle
  - L'avantage est que ça scale automatiquement avec le nombre de SM
- Threads
  - Contrairement aux blocks, les threads peuvent
    - Communiquer
    - Se synchroniser
  - Ces opérations sont à l'intérieur d'un block

Les paramètres du kernel

- Les blocks :
  - Le nombre de blocks doit être supérieur au nombre de SM (pour que tous travaillent)
  - Il devrait y avoir plusieurs blocks par SM, afin que d'autres blocks s'exécutent pendant une synchronisation

  → Si une synchronisation est utilisée, il vaut mieux utiliser plusieurs petits blocks qu'un grand
- Les threads :
  - Les SM ordonnancent les threads par groupe SIMD de 32 (warp) sur Quadro 620
    - Les threads d'un warp sont synchronisés

  → Les threads dans un block sont exécutés par groupe de 32
  - Un SM peut exécuter plusieurs blocks de manière concurrente

Les paramètres du kernel

- Les blocks :
  - Le nombre de blocks doit être supérieur au nombre de SM (pour que tous travaillent)
  - Il devrait y avoir plusieurs blocks par SM, afin que d'autres blocks s'exécutent pendant une synchronisation

  → Si une synchronisation est utilisée, il vaut mieux utiliser plusieurs petits blocks qu'un grand
- Les threads :
  - Les SM ordonnancent les threads par groupe SIMD de 32 (warp) sur Quadro 620
    - Les threads d'un warp sont synchronisés

  → Les threads dans un block sont exécutés par groupe de 32
  - Un SM peut exécuter plusieurs blocks de manière concurrente
  - Utiliser des blocks de taille multiple de la taille du warp

Les instructions de contrôles dans les warps

- Les instructions de contrôle (if, while, for, switch, do) affectent les performances, car les thread d'un warp vont diverger
- Les différents chemins sont sérialisés
- Lorsque toutes les exécutions sur les différents chemins sont finies, les threads convergent vers le même chemin
- Les conditions doivent minimiser les divergences
  - Par exemple une condition dépendant de $(threadIdx/warp\_size)$
- Il faut utiliser plus de threads CUDA que de nombre de cœurs CUDA pour augmenter le parallélisme

Exercice 4

Produit scalaire (dot product)

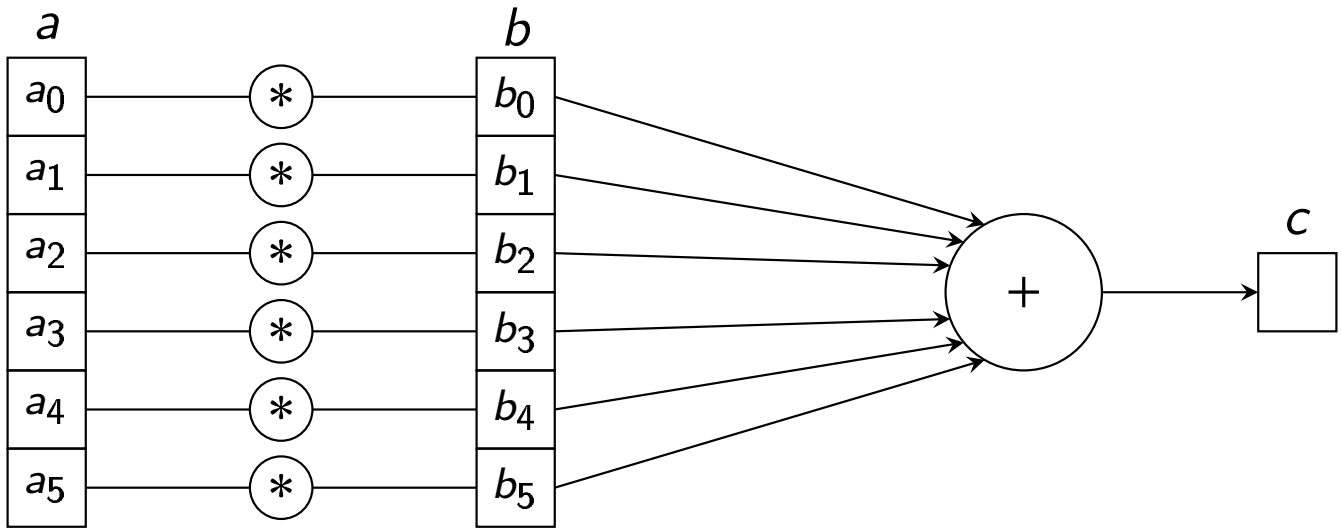

$$c = (a_0, a_1, a_2, a_3, a_4, a_5).(b_0, b_1, b_2, b_3, b_4, b_5)$$
$$= a_0 b_0 + a_1 b_1 + a_2 b_2 + a_3 b_3 + a_4 b_4 + a_5 b_5$$

Produit scalaire (dot product) : 1 seul block

```
__global__ void dot (int *a, int *b, int *c){
  // chaque thread calcule le produit d'une paire
  int tmp = a[threadIdx.x] * b[threadIdx.x];
}
```

Produit scalaire (dot product) : 1 seul block

```
__global__ void dot (int *a, int *b, int *c){
  // chaque thread calcule le produit d'une paire
  int tmp = a[threadIdx.x] * b[threadIdx.x];
}
```

- Le calcul est local au processus

→ Les variables `temp` ne sont pas accessibles aux autres processus

→ Mais il faut partager les données pour faire la somme finale

Partager les données entre les threads (d'un même block)

- Les threads d'un block partagent une zone mémoire appelée shared memory
- Caractéristiques
  - Extrêmement rapide
  - *on-chip*
  - Déclarée avec `__shared__`
- Des blocks sur le même SM partage la même mémoire partagée globale. Donc pour une mémoire de 48KB avec N blocks sur le même SM, chaque block possédera 48/N de mémoire partagée

Produit scalaire (dot product) : 1 seul block

```
#define N 512 //taille du tableau
__global__ void dot (int *a, int *b, int *c){
  __shared__ int tmp[N]
  // chaque thread calcule le produit d'une paire
  tmp[threadIdx.x] = a[threadIdx.x] * b[threadIdx.x
      ];

  //Le thread 0 effectue la somme
  if (0 == threadIdx.x){
    int sum = 0;
    for (int i = 0; i < N; i++)
      sum = sum + temp[i];
    *c = sum;
  }
}
```

Synchronisation des threads d'un même block

- Grâce à la fonction `__syncthreads()`
- Synchronise uniquement les threads d'un même block

Produit scalaire (dot product) : 1 seul block

```
#define N 512 //taille du tableau
__global__ void dot (int *a, int *b, int *c){
  __shared__ int tmp[N]
  // chaque thread calcule le produit d'une paire
  tmp[threadIdx.x] = a[threadIdx.x] * b[threadIdx.x
      ];

  //Synchronisation pour etre sur que tout les
      threads ont fini
  __syncthreads();

  //Le thread 0 effectue la somme
  if (0 == threadIdx.x){
    int sum = 0;
    for (int i = 0; i < N; i++)
      sum = sum + temp[i];
    *c = sum;
  }
}
```

Produit scalaire (dot product) : 1 seul block

```
int main (void){
  int *a, *b, *c;
  int *gpu_a, *gpu_b, *gpu_c;
  int size = N * sizeof(int);
  // allocation de l'espace pour le device}
  cudaMalloc((void **)&gpu_a, size);
  cudaMalloc((void **)&gpu_b, size);
  cudaMalloc((void **)&gpu_c, sizeof(int));

  a=(int*) malloc (size);
  b=(int*) malloc (size);
  random_ints(a, N);
  random_ints(b, N);
```

Programmation parallèle en CUDA : le main

```
// Copie des donnees vers le Device
cudaMemcpy (gpu_a,a,size,cudaMemcpyHostToDevice);
cudaMemcpy (gpu_b,b,size,cudaMemcpyHostToDevice);

//Lancement de l'operation avec N threads et un
    seul block
dot <<< 1, N >>> (gpu_a, gpu_b, gpu_c);

//Copie du resultat
cudaMemcpy(&c, gpu_c, sizeof(int),
    cudaMemcpyDeviceToHost);

free(a); free(b);
cudaFree(gpu_a);
cudaFree(gpu_b);
cudaFree(gpu_c);
return 0;
}
```

Plus de parallélisme : plusieurs blocks

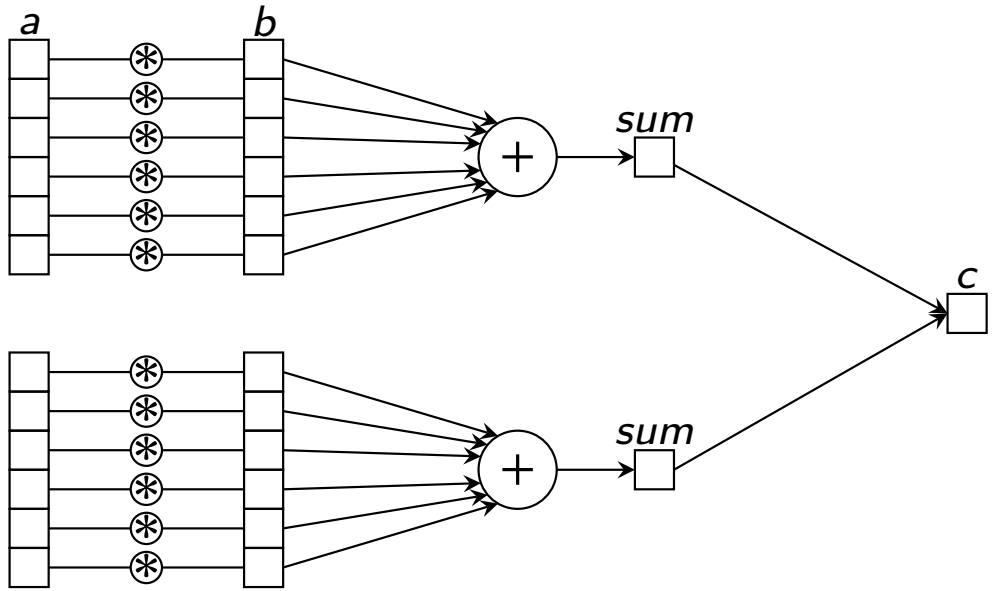

Produit scalaire (dot product)

```
#defin N (2048 * 2048)
#define THREAD_PER_BLOCK 512 //taille du tableau
__global__ void dot (int *a, int *b, int *c){
  __shared__ int tmp[THREADS_PER_BLOCK]
  // chaque thread calcule le produit d'une paire
  int indice = threadIdx.x + blockIdx.x * blockDim.
      x;
  tmp[threadIdx.x] = a[indice] * b[indice];

  //Synchronisation (dans le block)
  __syncthreads();

  //Le thread 0 effectue la somme
  if (0 == threadIdx.x){
    int sum = 0;
    for (int i = 0; i < THREADS_PER_BLOCK; i++)
      sum = sum + temp[i];
    *c = sum;
  }
}
```

Race condition

- c est dans la mémoire globale
- plusieurs thread 0 peuvent y accéder en même temps

Race condition

- c est dans la mémoire globale
- plusieurs thread 0 peuvent y accéder en même temps
- **Les opérations atomiques** :
  - Les opération de lecture, modification et écriture sont ininterruptibles
  - Plusieurs opérations atomiques possibles avec CUDA :

- `atomicAdd()`
- `atomicSub()`
- `atomicMin()`
- `atomicMax()`
- `atomicInc()`
- `atomicDec()`
- `atomicExch()`
- `atomicCAS()`

Produit scalaire (dot product)

```
#defin N (2048 * 2048)
#define THREAD_PER_BLOCK 512 //taille du tableau
__global__ void dot (int *a, int *b, int *c){
  __shared__ int tmp[THREADS_PER_BLOCK]
  // chaque thread calcule le produit d'une paire
  int indice = threadIdx.x + blockIdx.x * blockDim.
      x;
  tmp[threadIdx.x] = a[indice] * b[indice];

  //Synchronisation (dans le block)
  __syncthreads();

  //Le thread 0 effectue la somme
  if (0 == threadIdx.x){
    int sum = 0;
    for (int i = 0; i < THREADS_PER_BLOCK; i++)
      sum = sum + temp[i];
    atomicAdd(*c, sum);
  }
}
```

Produit scalaire (dot product)

```
int main (void){
  int *a, *b, *c;
  int *gpu_a, *gpu_b, *gpu_c;
  int size = N * sizeof(int);
  // allocation de l'espace pour le device}
  cudaMalloc((void **)&gpu_a, size);
  cudaMalloc((void **)&gpu_b, size);
  cudaMalloc((void **)&gpu_c, size);

  a=(int*) malloc (size);
  b=(int*) malloc (size);
  c=(int*) malloc (sizeof(int));
  random_ints(a, N);
  random_ints(b, N);
```

Produit scalaire (dot product)

```
// Copie des donnees vers le Device
cudaMemcpy (gpu_a,a,size,cudaMemcpyHostToDevice);
cudaMemcpy (gpu_b,b,size,cudaMemcpyHostToDevice);

//Lancement de l'operation avec THREAD_PER_BLOCK
    par block
add <<< N/THREAD_PER_BLOCK,THREAD_PER_BLOCK >>> (
    gpu_a, gpu_b, gpu_c);

//Copie du resultat
cudaMemcpy(c, gpu_c, size, cudaMemcpyDeviceToHost);

free(a); free(b);
cudaFree(gpu_a);
cudaFree(gpu_b);
cudaFree(gpu_c);
return 0;
}
```

Exercice 5

Les optimisations de base

`http://docs.nvidia.com/cuda/cuda-c-best-practices-guide/`

- ✓ Les paramètres du kernel
- ✓ Les instructions de contrôle
- × Les mémoires

Throughput de la mémoire

1. Minimiser les transferts de faible BW
   → Minimiser les transfert Host<->Device

2. Minimiser les transferts mémoire globale<->Device
   → Favoriser la mémoire partagée et les caches
   - La mémoire partagée est équivalente à un cache géré par l'utilisateur

La mémoire globale

- Lorsque tous les threads font un load, le hardware détecte si les threads accèdent à un espace mémoire contigu
- Dans ce cas, le hardware groupe (*coalesces*) les accès en un seul accès à différentes location de la DRAM

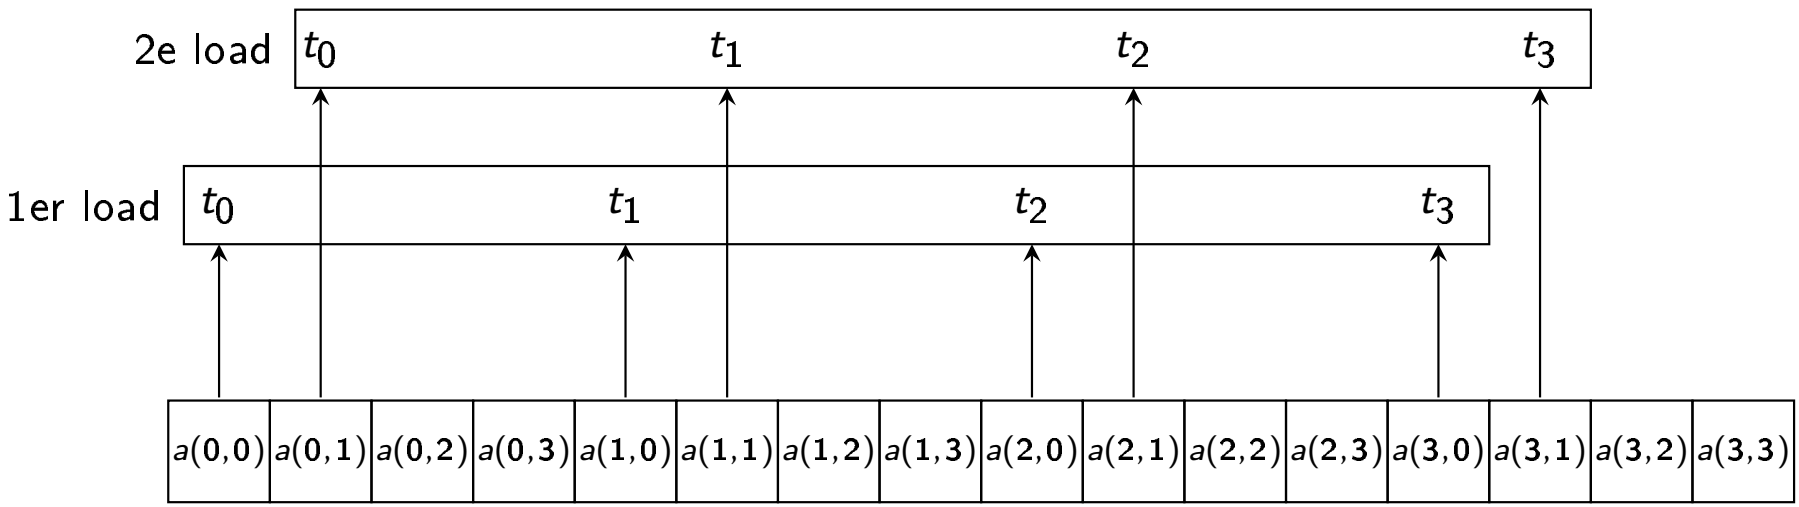

La mémoire globale

- Lorsque tous les threads font un load, le hardware détecte si les threads accèdent à un espace mémoire contigu
- Dans ce cas, le hardware groupe (*coalesces*) les accès en un seul accès à différentes location de la DRAM

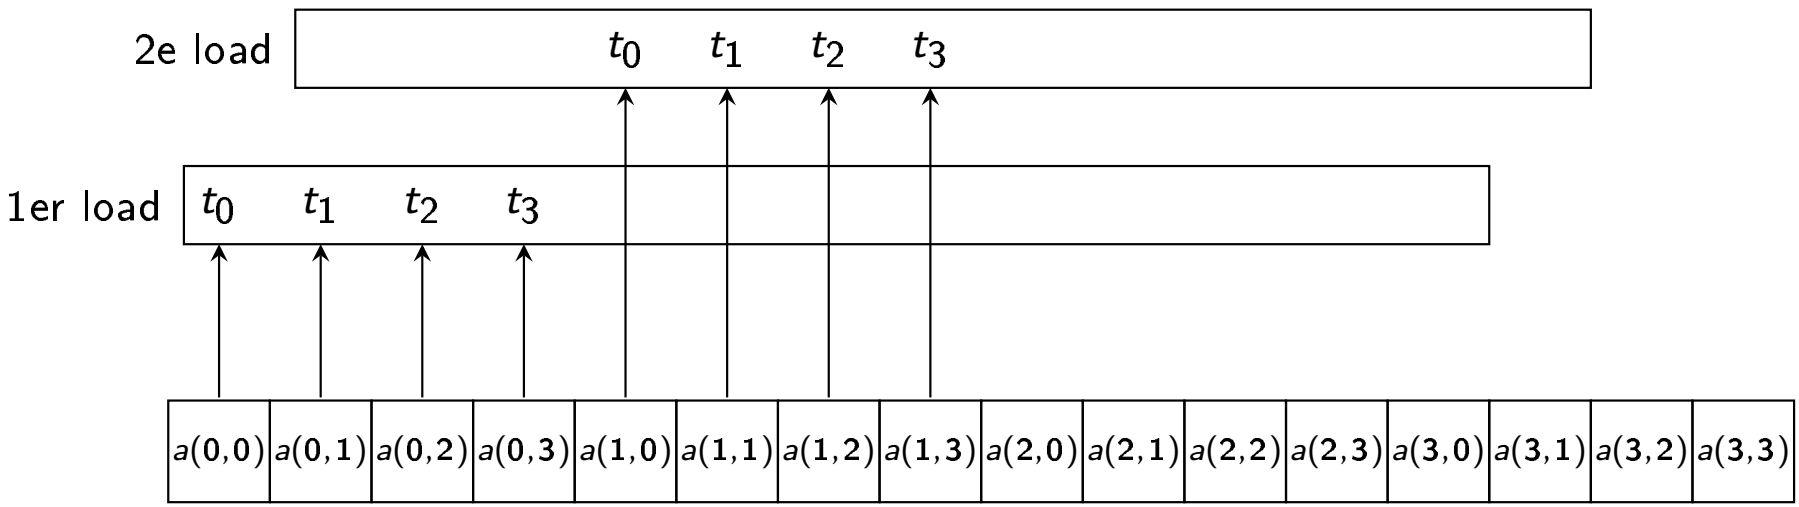

La mémoire partagée

- À utiliser pour éviter les accès non alignés
- La mémoire est partagée en modules de taille égale, appelés *bank*
- Il y a autant de *bank* que de threads dans un *warp*
- L'accès aux *bank* est simultané

→ Toute lecture/écriture de n adresses dans n bank différents est simultané

La mémoire partagée

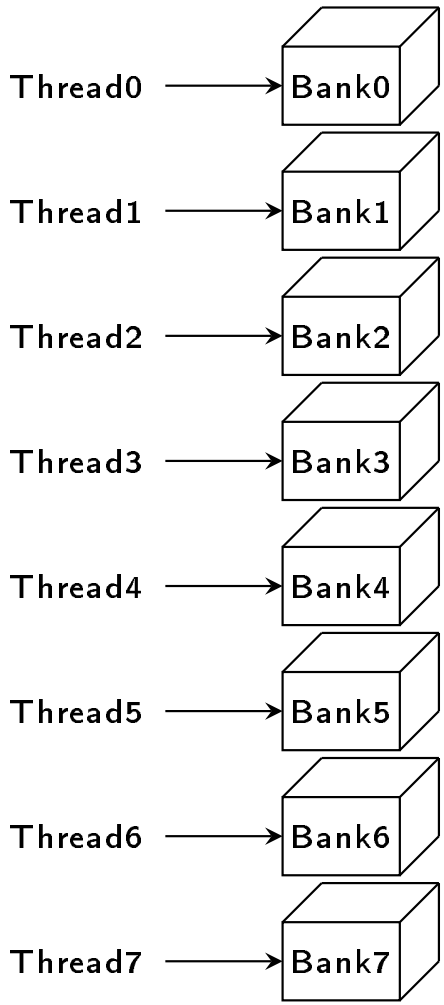

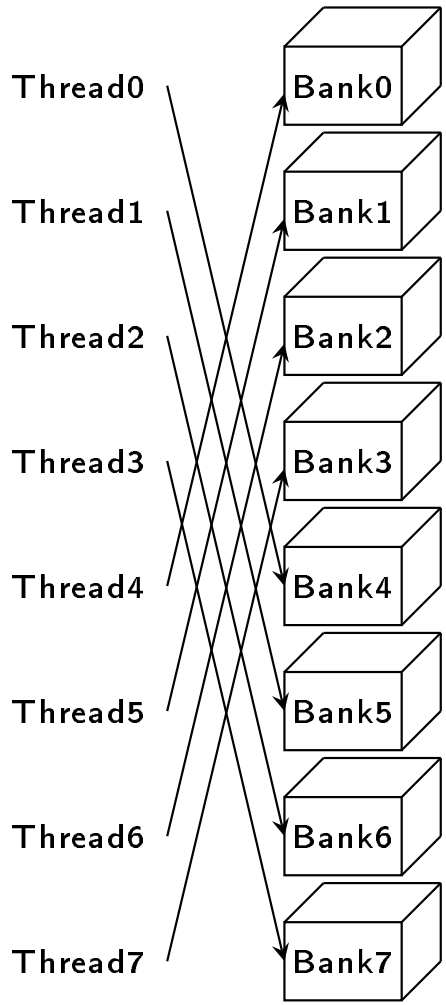

Bank conflict

- Si deux accès sont dans différentes adresses du même *bank*, il y a conflit

☹ L'accès en cas de conflit est sérialisé

- La mémoire partagée est rapide tant qu'il n'y a pas de *bank conflict*

- Le hardware divise un accès mémoire avec conflit en autant d'accès nécessaire pour ne plus avoir de conflit

☹ La BW est réduite par un facteur égal au nombre d'accès créés pour éviter les conflits

Bank conflict

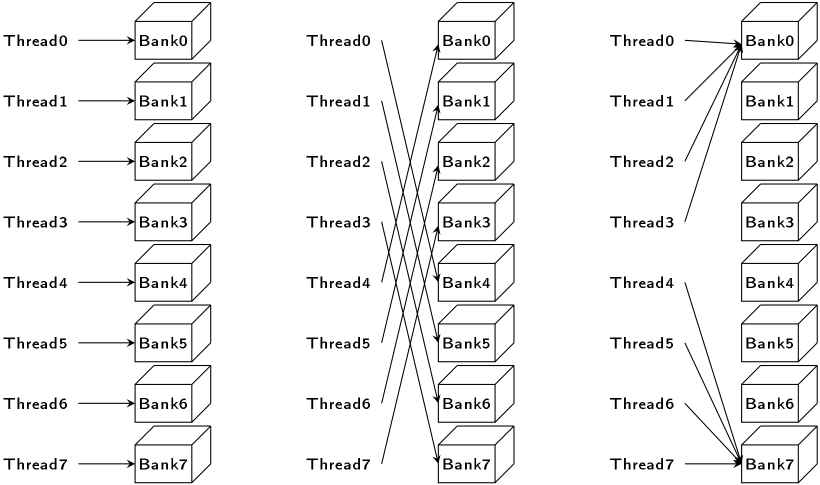

Mesure du temps

- Les transferts de données sont synchrones
- L'appel au kernel ne l'est pas

```
cudaMemcpy(d_x, x, N*sizeof(float),
    cudaMemcpyHostToDevice);
cudaMemcpy(d_y, y, N*sizeof(float),
    cudaMemcpyHostToDevice);

t1 = myCPUTimer();
saxpy<<<(N+255)/256, 256>>>(N, 2.0, d_x, d_y);
cudaDeviceSynchronize();
t2 = myCPUTimer();

cudaMemcpy(y, d_y, N*sizeof(float),
    cudaMemcpyDeviceToHost);
```

Mesure du temps

- CUDA event API
- Les opérations sont séquentielles sur le GPU

```
cudaEvent_t start, stop;
cudaEventCreate(&start);
cudaEventCreate(&stop);
...
cudaEventRecord(start);//le temps est sauvegarde
    sur le GPU
saxpy<<<(N+255)/256, 256>>>(N, 2.0f, d_x, d_y);
cudaEventRecord(stop);

cudaEventSynchronize(stop);//Garantit que l'
    evenement s'est execute : le CPU se bloque en
    attendant le record de l'evenement
...
float milliseconds = 0;
cudaEventElapsedTime(&milliseconds, start, stop);
```

Profiling d'une application CUDA

1. nvprof (***deprecated***)
   - `nvprof ./saxpy`
   - `nvprof -o trace.prof ./saxpy`
   - Ensuite ouverture de la trace avec : `nvvp -import trace.prof`

2. nsys
   - `nsys profile ./saxpy`
   - Visualisation de la trace avec : `nsys-ui fichier.qdrep`
   - Statistiques sur une exécution : `nsys stats fichier.qdrep`

Mesure de la puissance consommée

- `nvidia-smi` (System Management Interface) permet de questionner l'état du GPU
- Pour afficher la mesure toutes les secondes

```
nvidia-smi -query-gpu=power.draw -format=csv -l 1
```

Exercice 6

Nombre de threads dans les blocks pour le produit de matrices

- Chaque SM du GeForce RTX 2070 possède 48KB de mémoire partagée par block
- TILE_WIDTH = 16 :
  - 2 vecteur de mémoire partagée de float d'une taille de

  → 2 x 4B x 16 x 16 = 2KB pour un block
  - Donc jusqu'à 24 blocks pouvant s'exécuter sur le même SM
- TILE_WIDTH = 32
  - 2 vecteur de mémoire partagée de float d'une taille de

  → 2 x 4B x 32 x 32 = 8KB pour un block
  - Donc jusqu'à 6 blocks pouvant s'exécuter sur le même SM
- Mais dans la vraie vie, on utilise des bibliothèques (cuBlas)

Parallélisme de tâches avec des GPU : les streams

Les streams

- Un stream : Une séquence d'opérations (comme une file d'attente pour le device)
- Stream par défaut : stream 0
  - Opérations de lecture et d'écriture synchrone (*HostToDevice* et *DeviceToHost*) avec le host
  - Les *kernels* sont asynchrones avec le host par défaut (des opérations CPU sont possibles)

Les streams

- Stream différents du stream 0
- Les opérations sur un même stream sont ordonnées (FIFO) et syncrhones
- Les opérations dans des streams différents peuvent s'exécuter en parallèle
- Les opérations entre les différents streams peuvent s'intercaler
- Le stream par défaut est synchrones avec les autres streams

Exemple d'exécution

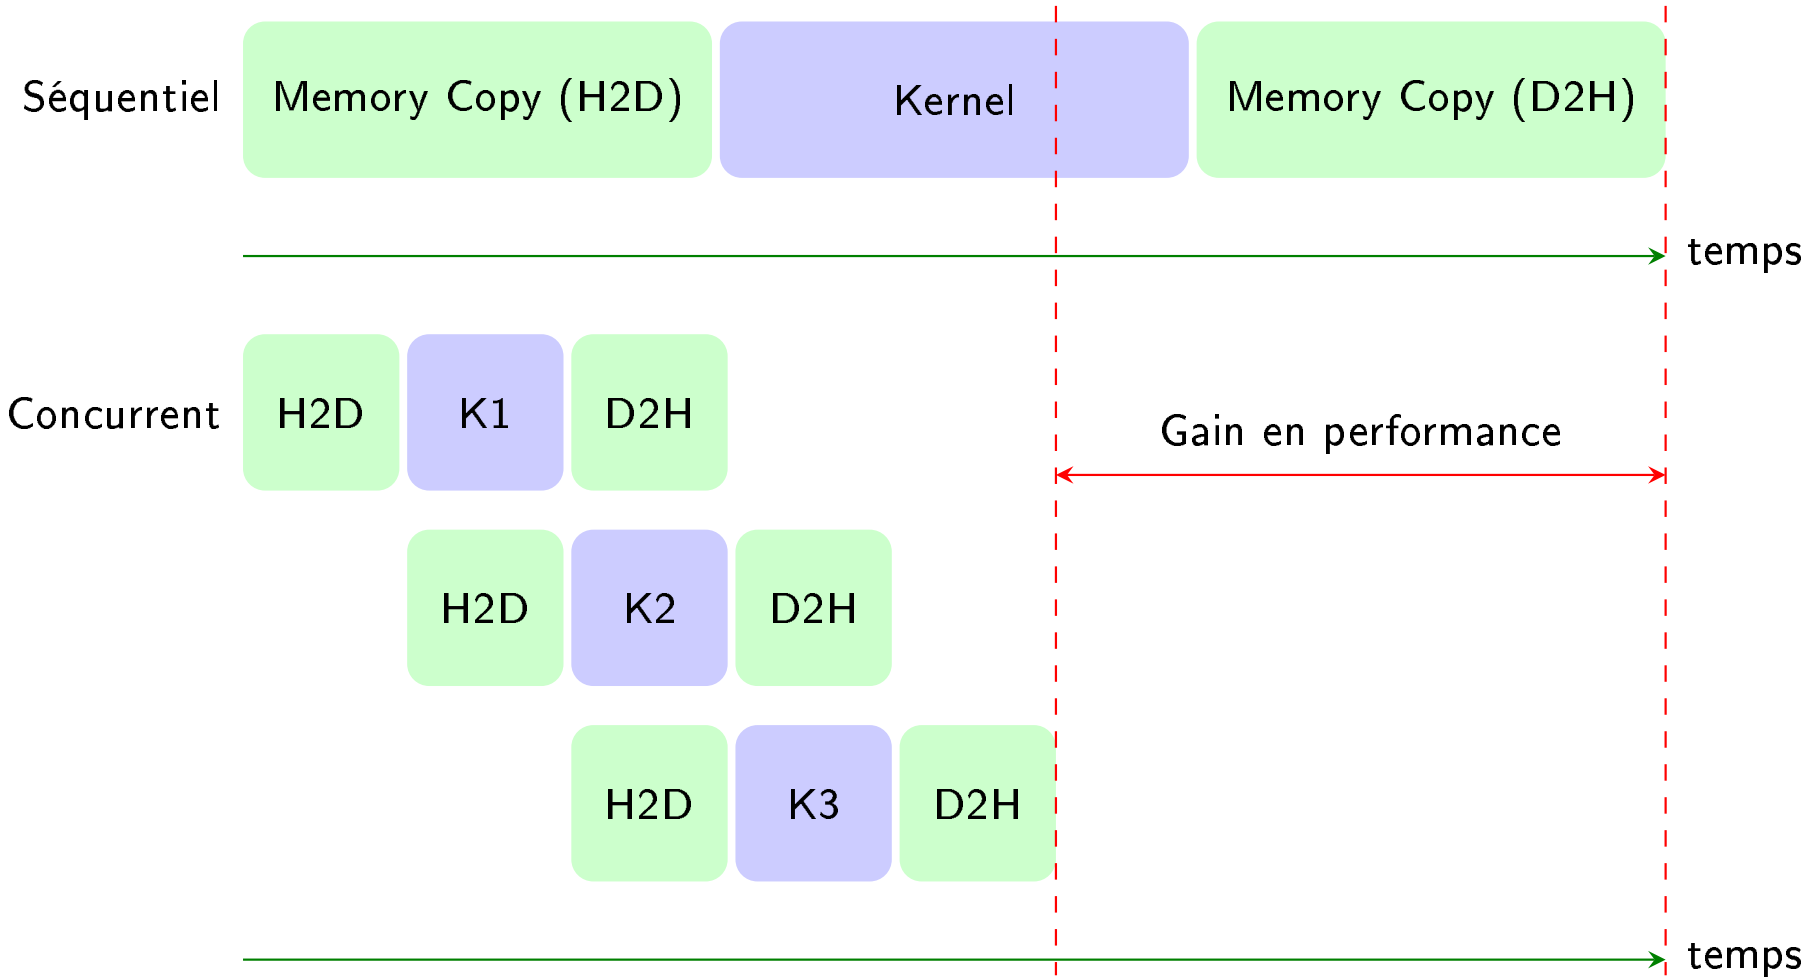

Exemple de code avec streams

```
cudaStream_T stream1, stream2, stream3, stream4;
cudaStreamCreate(&stream1);
...
cudaMalloc(&data_dev1, size);
...
cudaMemcpyAsync(data_dev1, data_host1, size,
    cudaMemcpyHostToDevice, stream1);
kernel2 <<< grid, block, 0, stream2 >>> (...,
    data_dev2, ...);
kernel3 <<< grid, block, 0, stream3 >>> (...,
    data_dev3, ...);
cudaMemcpyAsync(data_host4, data_dev4, size,
    cudaMemcpyDeviceToHost, stream4);
...
```

L'ordre d'émission des opérations est important

- Stream 1 : K1a, K1b
- Stream 2 : K2a, K2b

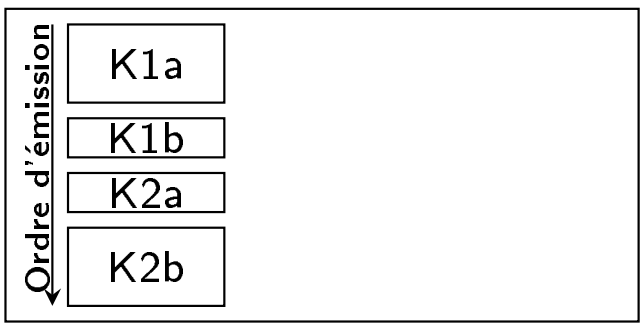

L'ordre d'émission des opérations est important

- Stream 1 : K1a, K1b
- Stream 2 : K2a, K2b

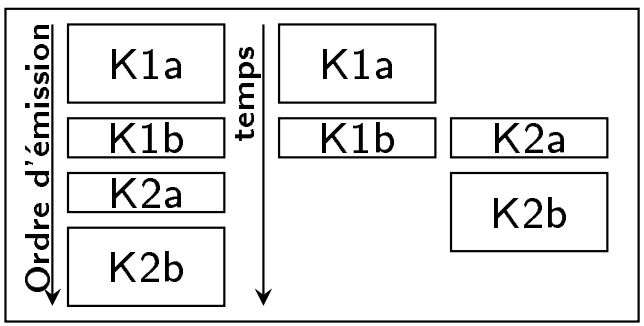

L'ordre d'émission des opérations est important

- Stream 1 : K1a, K1b
- Stream 2 : K2a, K2b

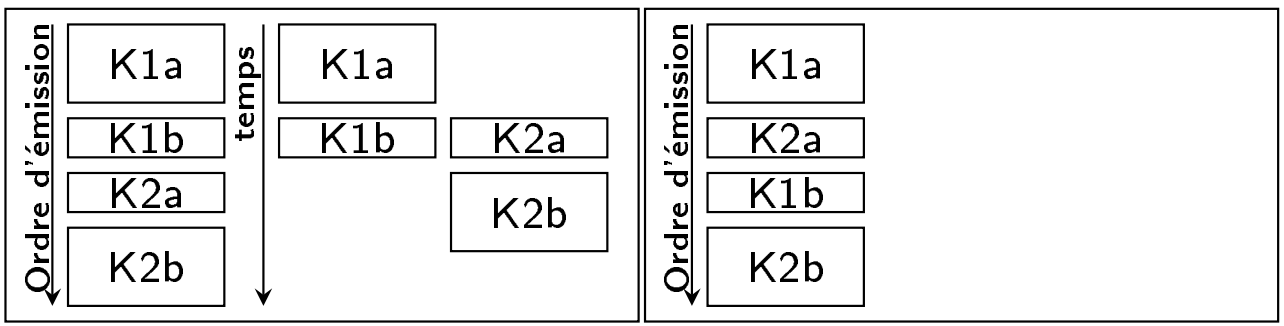

L'ordre d'émission des opérations est important

- Stream 1 : K1a, K1b
- Stream 2 : K2a, K2b

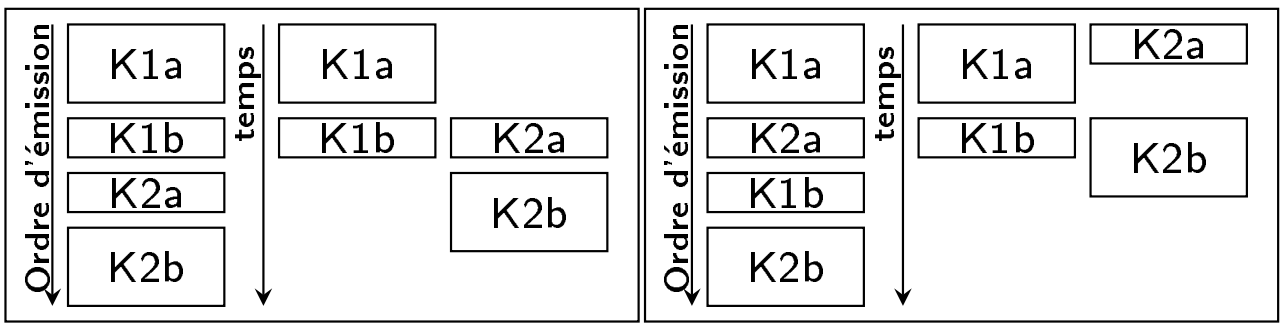

L'ordre d'émission des opérations est important

- Stream 1 : K1a, K1b
- Stream 2 : K2a, K2b

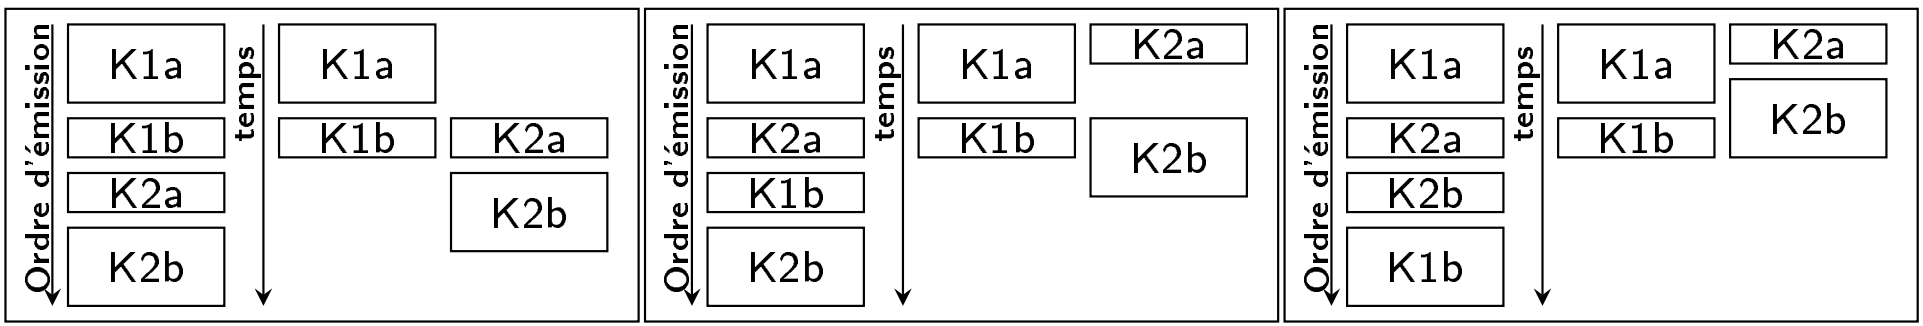

Étude de différents cas d'utilisation (et d'erreurs) avec les streams (1/2)

- Problèmes de performances simple à corriger (à vous de jouer : exercice 7)

Étude de différents cas d'utilisation (et d'erreurs) avec les streams (1/2)

- Problèmes de performances simple à corriger (à vous de jouer : exercice 7)
- Symptômes
  - Un stream ne s'overlap pas avec les autres

Étude de différents cas d'utilisation (et d'erreurs) avec les streams (1/2)

- Problèmes de performances simple à corriger (à vous de jouer : exercice 7)
- Symptômes
  - Un stream ne s'overlap pas avec les autres

  ⇒ Chercher le stream par défaut

Étude de différents cas d'utilisation (et d'erreurs) avec les streams (1/2)

- Problèmes de performances simple à corriger (à vous de jouer : exercice 7)
- Symptômes
  - Un stream ne s'overlap pas avec les autres

  $\Rightarrow$ Chercher le stream par défaut

- Solutions
  - Lancer bien un kernel par stream (on évite le stream par défaut)

Étude de différents cas d'utilisation (et d'erreurs) avec les streams (1/2)

- Problèmes de performances simple à corriger (à vous de jouer : exercice 7)
- Symptômes
  - Un stream ne s'overlap pas avec les autres

  ⇒ Chercher le stream par défaut

  ⇒ Cherchez `cudaEventRecord`
- Solutions
  - Lancer bien un kernel par stream (on évite le stream par défaut)

Étude de différents cas d'utilisation (et d'erreurs) avec les streams (1/2)

- Problèmes de performances simple à corriger (à vous de jouer : exercice 7)
- Symptômes
  - Un stream ne s'overlap pas avec les autres

  ⇒ Chercher le stream par défaut

  ⇒ Cherchez `cudaEventRecord`

- Solutions
  - Lancer bien un kernel par stream (on évite le stream par défaut)
  - Associer le stream à `cudaEventRecord`

Étude de différents cas d'utilisation (et d'erreurs) avec les streams (1/2)

- Problèmes de performances simple à corriger (à vous de jouer : exercice 7)
- Symptômes
  - Un stream ne s'overlap pas avec les autres

  ⇒ Chercher le stream par défaut

  ⇒ Cherchez `cudaEventRecord`
  - Les copies mémoires ne s'overlapent pas
- Solutions
  - Lancer bien un kernel par stream (on évite le stream par défaut)
  - Associer le stream à `cudaEventRecord`

Étude de différents cas d'utilisation (et d'erreurs) avec les streams (1/2)

- Problèmes de performances simple à corriger (à vous de jouer : exercice 7)
- Symptômes
  - Un stream ne s'overlap pas avec les autres

  ⇒ Chercher le stream par défaut

  ⇒ Cherchez `cudaEventRecord`
  - Les copies mémoires ne s'overlapent pas
- Solutions
  - Lancer bien un kernel par stream (on évite le stream par défaut)
  - Associer le stream à `cudaEventRecord`
  - Utiliser la version asynchrone `cudaMemcpyAsync`
  - Associer un stream différent à `cudaMemcpyAsync`

Référence : `https://on-demand.gputechconf.com/gtc/2014/presentations/S4158-cuda-streams-best-practices-common-pitfalls.pdf`

Pour aller plus loin dans la gestion de la mémoire

- Beaucoup de temps est passé dans l'API pour la copie (`cudaMemCpy`)
- Cuda indique que la mémoire est *pageable*

⇒ La mémoire est transférée via le host

⇒ La mémoire peut-être page-in et out par le système

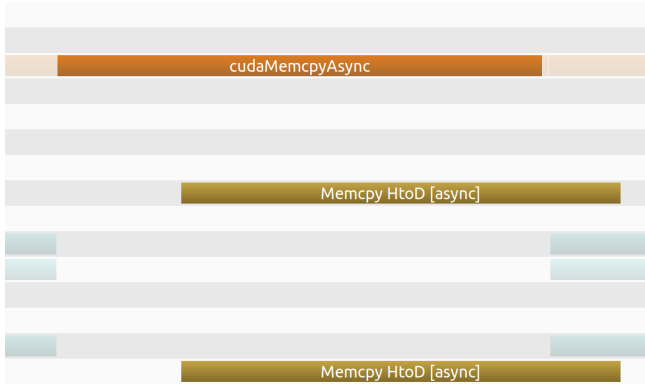

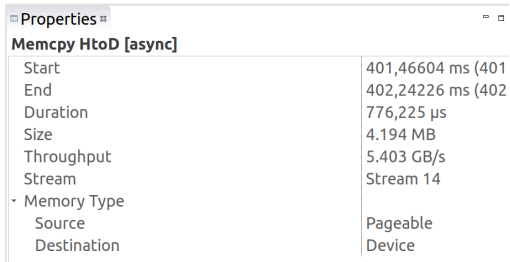

⚠ Afin que `cudaMemCpyAsync` soit réellement asynchrone (en plus des streams), il faut que la mémoire soit pinnée, sinon les opérations sur le GPU sont sérialisées.

Pour aller plus loin dans la gestion de la mémoire

- Utiliser un mécanisme pour *pin* la mémoire
- Elle devient accessible directement depuis le GPU
- Il n'est pas possible pour le système de faire page-in ou page-out

⇒ La mémoire transférée via le moteur DMA

- cudaHostMalloc à la place de malloc (ou cudaHostRegister)
  - Bande passante plus élevée
  - Libère le CPU pour une exécution asynchrone

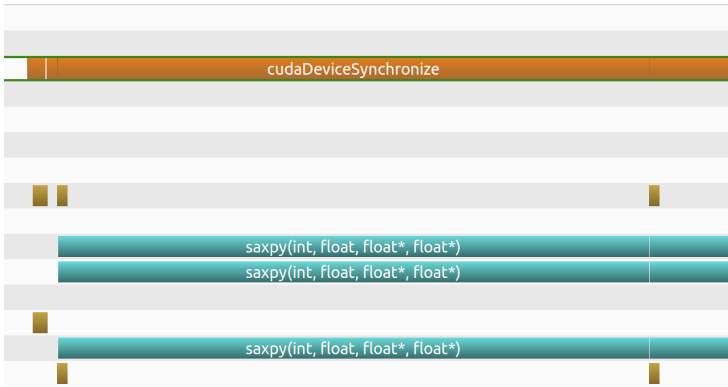

Start	371,87683 ms (371
End	372,4608 ms (372 4
Duration	583,969 µs
Size	4.194 MB
Throughput	7.182 GB/s
Stream	Stream 14
▾ Memory Type	
Source	Pinned
Destination	Device

On remarquera que le `MemcpyAsync` a disparu

Pour aller plus loin dans la gestion de la mémoire

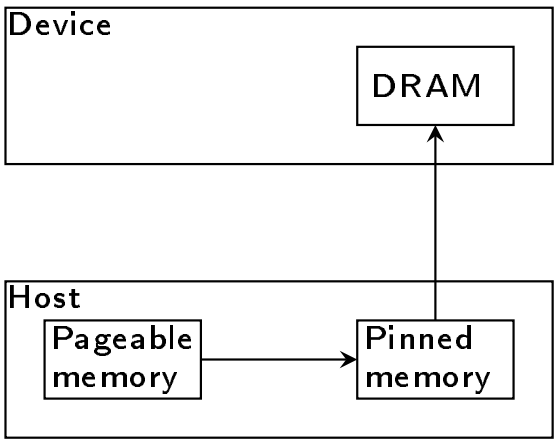

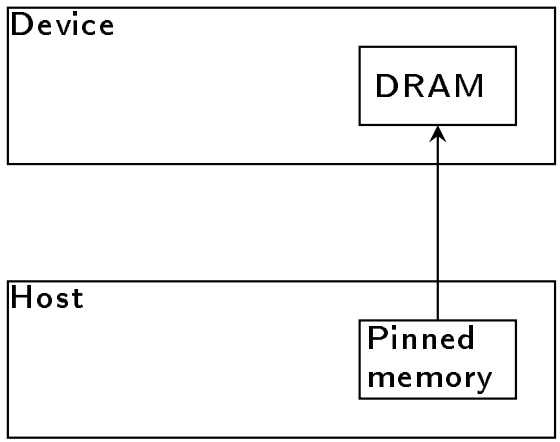


```
cudaHostRegister(y, N*sizeof(float),0);

    for(int i = 0; i < 10; i ++){
  cudaMemcpyAsync(gpu_y, y, N*sizeof(float),
      cudaMemcpyHostToDevice, stream2);
  saxpy<<<1, 1, 0, stream1>>>(N, 2.0f, gpu_x,
      gpu_y);
  cudaDeviceSynchronize();
}
cudaHostUnregister(y);
```

Référence : https://medium.com/analytics-vidhya/cuda-memory-model-823f02cef0bf

Accès à la mémoire

Différents types de mémoire

- La mémoire du GPU
  - Allouée via cudaMalloc
  - Ne peut pas être paged
- La mémoire du CPU
  - Allouée avec malloc(callo, new, . . .)
  - Peut-être page-in et page-out par le système
- La mémoire pinned sur le CPU
  - Allouée via cudaMallocHost
  - Ne peut-être page-in et page-out par le système
- La mémoire mapped
  - Mémoire pinned mais mappéedans la mémoire du GPU
  - Les données ne sont pas sur le GPU : elles sont copiées à l'exécution
- Mémoire unifiée : une même zone mémoire accessible directement depuis le CPU et le GPU (le meilleur des deux mondes)

Référence : `https://on-demand.gputechconf.com/gtc/2014/presentations/S4158-cuda-streams-best-practices-common-pitfalls.pdf`

Différents accès à la mémoire

- Accès via des `memcpy` explicites
  - ☺ Bonnes performances (car les données sont disponibles)
  - ☹ Code assez lourd et erreurs fréquentes
  - ☹ Accès uniquement à la mémoire du GPU
- Accès via un mécanisme *Zero Copy* (non abordé dans ce cours) : les thread GPU accèdent directement à l'espace mémoire du CPU (via les fonctions `cudaHostAlloc` et `cudaHostGetDevicePointer`).
  - ☺ Accès à toute la mémoire
  - ☹ Vitesse limitée par le bus PCI et NVLink
  - ☹ Pas de localité des données : les données ne sont pas copiées sur le GPU. Le transfert se fait à l'exécution
- Mémoire unifiée : une même zone mémoire accessible directement depuis le CPU et le GPU (le meilleur des deux mondes)

Référence : `https://developer.nvidia.com/blog/maximizing-unified-memory-performance-cuda/`

Exemple d'utilisation de la mémoire unifiée

```
int *a, *b;
int *gpu_a, *gpu_b;
cudaMalloc((void **)&gpu_a, N*sizeof(int));
cudaMalloc((void **)&gpu_b, N*sizeof(int));
a=(int*) malloc (N*sizeof(int));
b=(int*) malloc (N*sizeof(int));
for (int i = 0; i < N; i++) {
    x[i] = 1.0f;
    y[i] = 2.0f;
  }
cudaMemcpy (gpu_a,a,N*sizeof(int),cudaMemcpyHostToDevice);
cudaMemcpy (gpu_b,b,N*sizeof(int),cudaMemcpyHostToDevice);
add <<< N, 1 >>> (gpu_a, gpu_b);
cudaMemcpy(b, gpu_b, N*sizeof(int), cudaMemcpyDeviceToHost);
free(a); free(b);
cudaFree(gpu_a);
cudaFree(gpu_b);
```

Exemple d'utilisation de la mémoire unifiée

```
int *a, *b;
int *gpu_a, *gpu_b;
cudaMalloc((void **)&gpu_a, N*sizeof(int));
cudaMalloc((void **)&gpu_b, N*sizeof(int));
a=(int*) malloc (N*sizeof(int));
b=(int*) malloc (N*sizeof(int));
for (int i = 0; i < N; i++) {
    x[i] = 1.0f;
    y[i] = 2.0f;
  }
cudaMemcpy (gpu_a,a,N*sizeof(int),cudaMemcpyHostToDevice);
cudaMemcpy (gpu_b,b,N*sizeof(int),cudaMemcpyHostToDevice);
add <<< N, 1 >>> (gpu_a, gpu_b);
cudaMemcpy(b, gpu_b, N*sizeof(int), cudaMemcpyDeviceToHost);
free(a); free(b);
cudaFree(gpu_a);
cudaFree(gpu_b);
```

Exemple d'utilisation de la mémoire unifiée

```
int *a, *b;
cudaMallocManaged(a, N*sizeof(int));
cudaMallocManaged(b, N*sizeof(int));
for (int i = 0; i < N; i++) { // operations effectuees
    par le CPU
    x[i] = 1.0f;
    y[i] = 2.0f;
  }
add <<< N, 1 >>> (a, b);

cudaFree(a);
cudaFree(b);
```

Référence : https://developer.nvidia.com/blog/unified-memory-cuda-beginners/

Exemple d'utilisation de la mémoire unifiée

```
int *a, *b;
cudaMallocManaged(a, N*sizeof(int));
cudaMallocManaged(b, N*sizeof(int));
for (int i = 0; i < N; i++) { // operations effectuees
    par le CPU
    x[i] = 1.0f;
    y[i] = 2.0f;
  }
add <<< N, 1 >>> (a, b);
cudaDeviceSynchronize();
cudaFree(a);
cudaFree(b);
```

Référence : https://developer.nvidia.com/blog/unified-memory-cuda-beginners/

Pourquoi on s'est embêtés à parler des `memcpy`

- La mémoire unifiée n'est disponible que depuis CUDA 6.0
- Selon les architectures, le fonctionnement n'est pas le même (plus d'explication au slide suivant)

Fonctionnement de la mémoire unifiée

1. Pré-Pascal
   - Allocation de tout l'espace (les pages) sur le GPU
   - Lorsque le CPU rempli le tableau (la boucle for), les pages doivent être chargées sur le CPU (donc défauts de page)
   - Lorsque le kernel est appelé, les pages sont de nouveau rechargées sur le GPU (les défauts de page de sont pas possibles sur les anciennes architectures)
2. Pascal
   - Les pages peuvent n'être allouées que lors de l'accès
   - Les défauts de page sont possibles (donc de l'overhead)

   $\Rightarrow$ Pour éviter cela, nous pouvons utiliser des techniques de prefetching, ou initialiser le tableau dans un kernel GPU

Mémoire unifiée : le prefetching

- La migration on-demand permet un meilleur overlap entre le transfert des données et le calcul, mais il y les défauts de page.
- Si le schéma d'accès aux données est connu, il est possible d'utiliser `cudaMemPrefetchAsync`.

```
cudaGetDevice(&device); // recuperer le
    numero du device
cudaMemPrefetchAsync(x, N*sizeof(float),
    device, stream);
```

Référence : https://developer.nvidia.com/blog/maximizing-unified-memory-performance-cuda/

Mémoire unifiée : le prefetching

Sans Prefetch

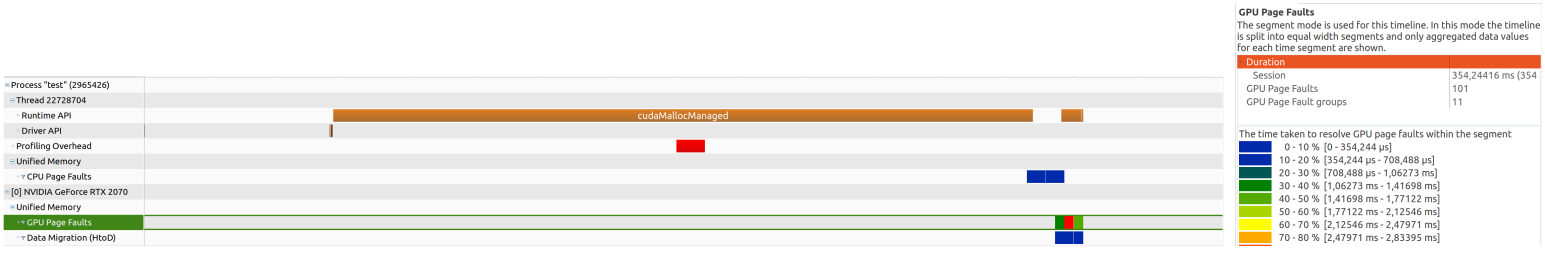

Avec Prefetch

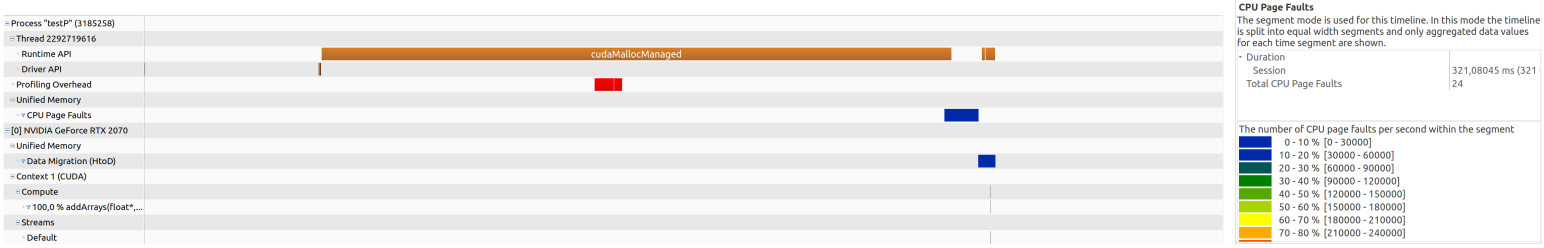

Pour aller plus loin

- MPI + CUDA :
  `http://on-demand.gputechconf.com/gtc/2014/presentations/S4236-multi-gpu-programming-mpi.pdf`
- Mémoire unifiée CPU + GPU :
  `http://www.drdobbs.com/parallel/unified-memory-in-cuda-6-a-brief-overvie/240169095?pgno=1`

Multiplication de matrice

- C(0,0) -> blockIdx.x=0,blockIdx.y=0
- C(0,1) -> blockIdx.x=1,blockIdx.y=0
- C(1,0) -> blockIdx.x=0,blockIdx.y=1
- C(1,1) -> blockIdx.x=1,blockIdx.y=1

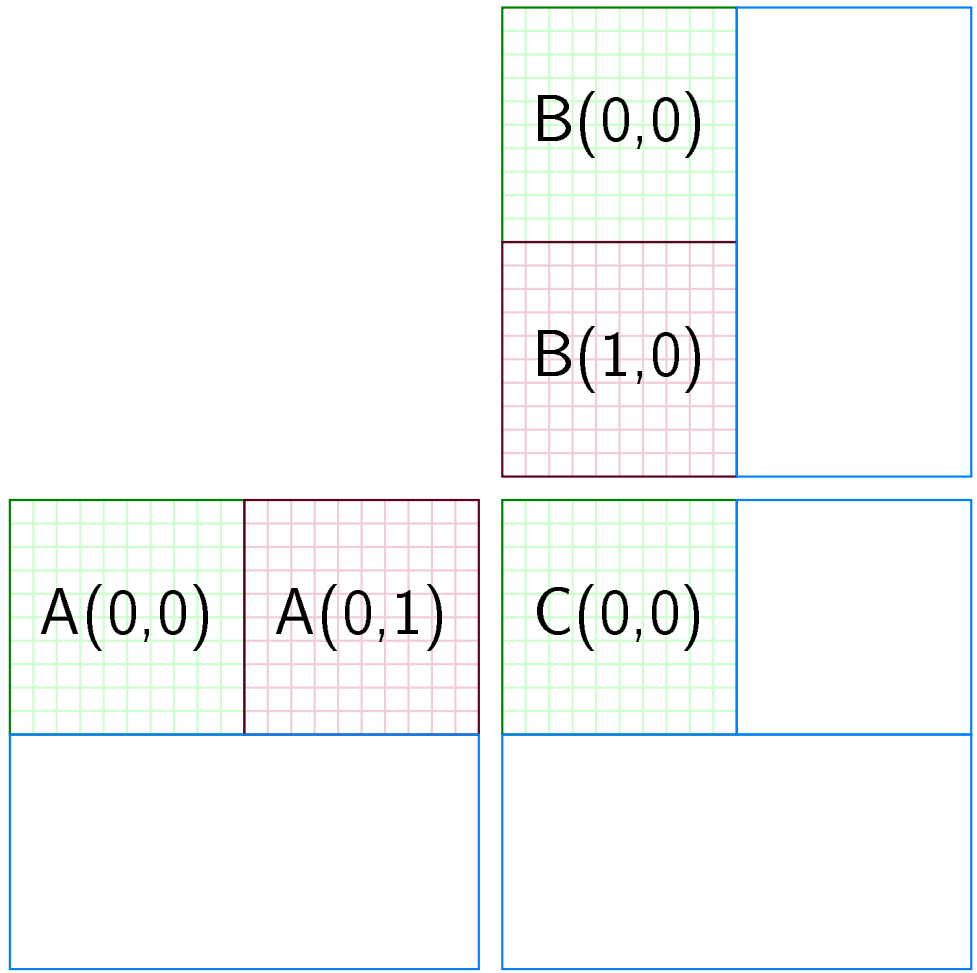

Multiplication de matrice

- 1 block calcule une tuile
- 1 thread calcule un élément de la tuile

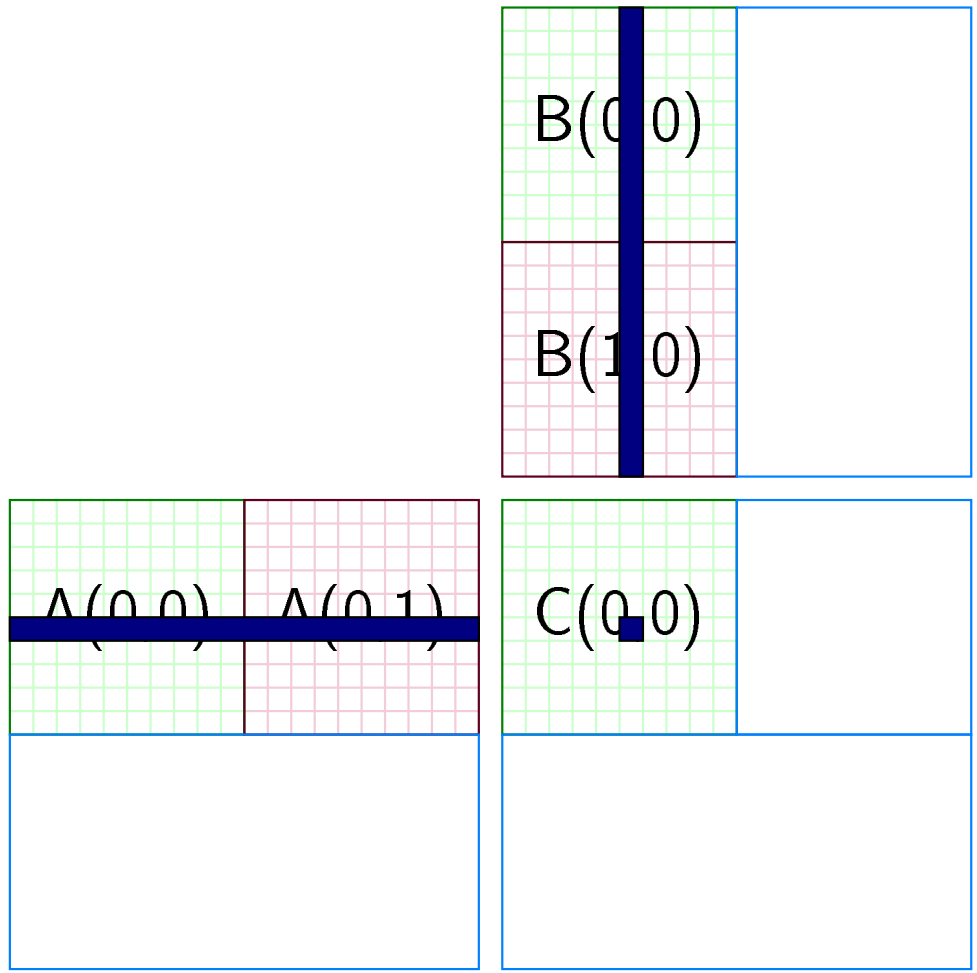

Multiplication de matrice

- Les blocks A(0,0) et B(0,0) sont chargés en mémoire partagée de façon collaborative par les threads (chacun charge un élément de chaque tuile)
- Les threads font le calcul partiel de C
- Chaque valeur est gardée dans le registre du thread

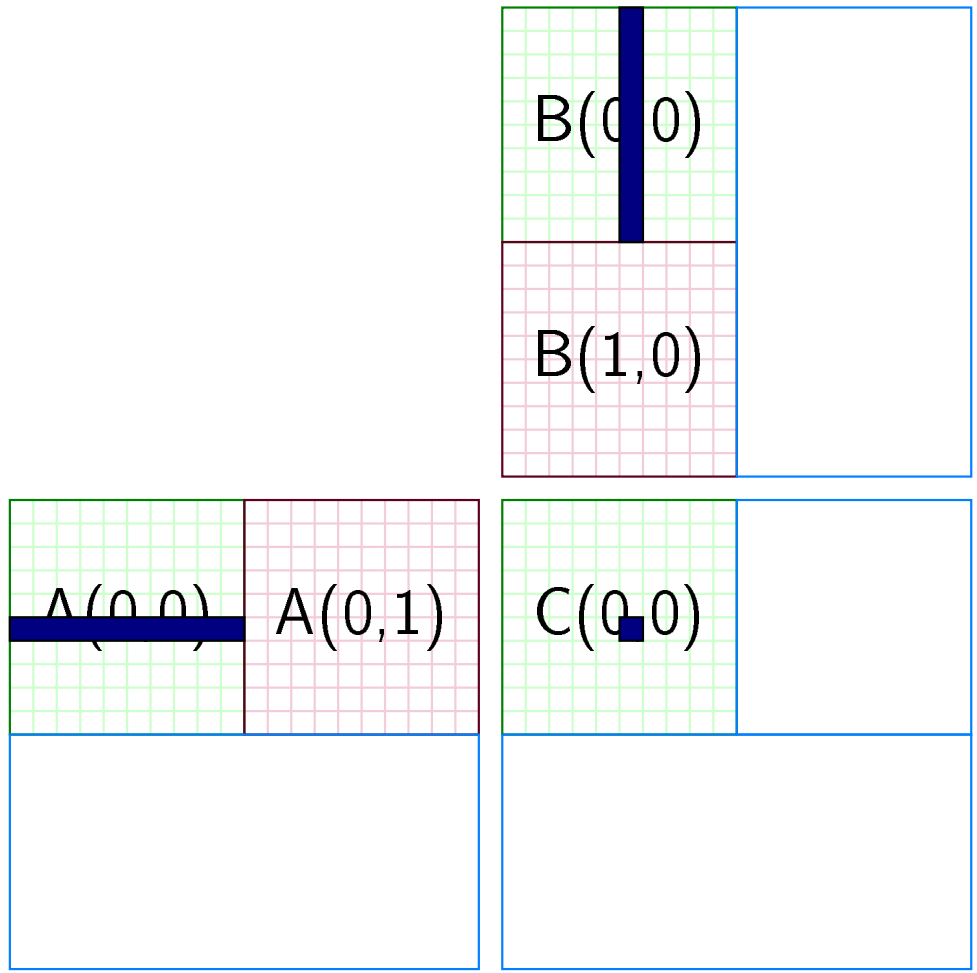

Multiplication de matrice

- Les blocks A(0,1) et B(1,0) sont chargés en mémoire partagée
- Les threads terminent le calcul de C
- À la fin, C est stockée en mémoire globale

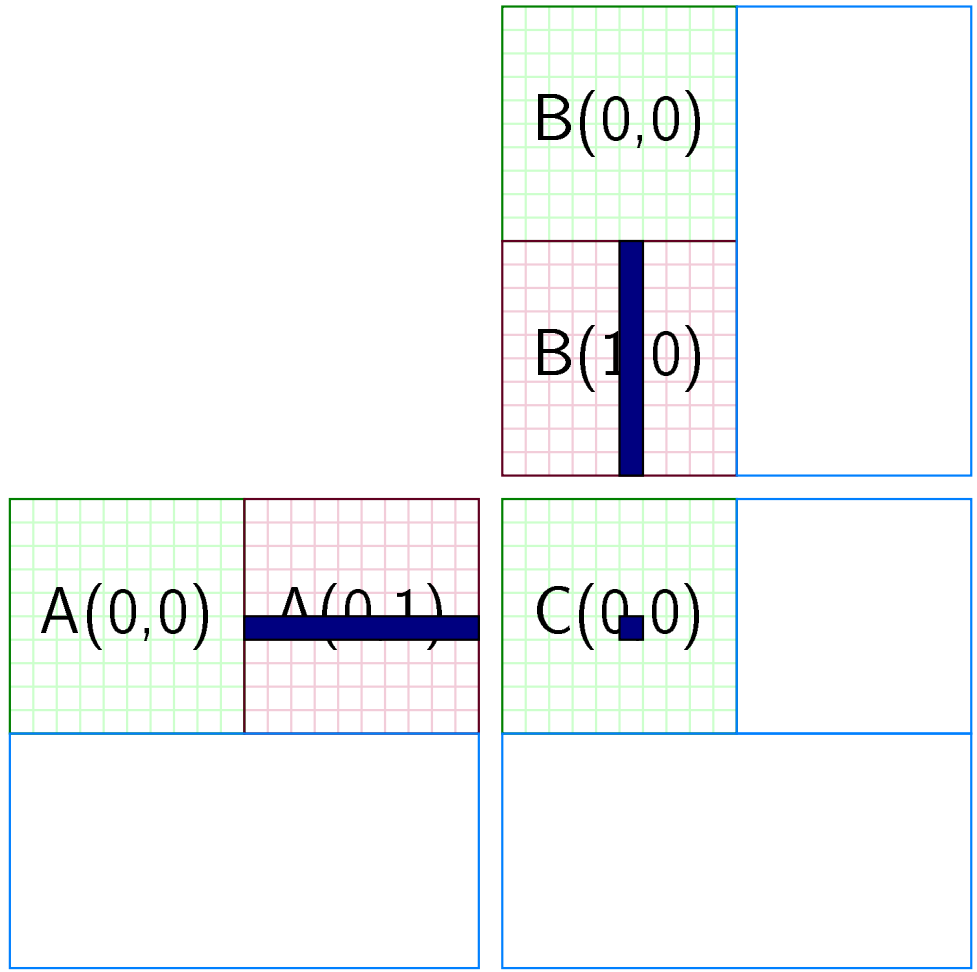

Les indices dans le produit de matrices par tuile : A

- `col = blockIdx.x*blockDim.x+theadIdx.x`
- `ligne = blockIdx.y*blockDim.y+theadIdx.y`

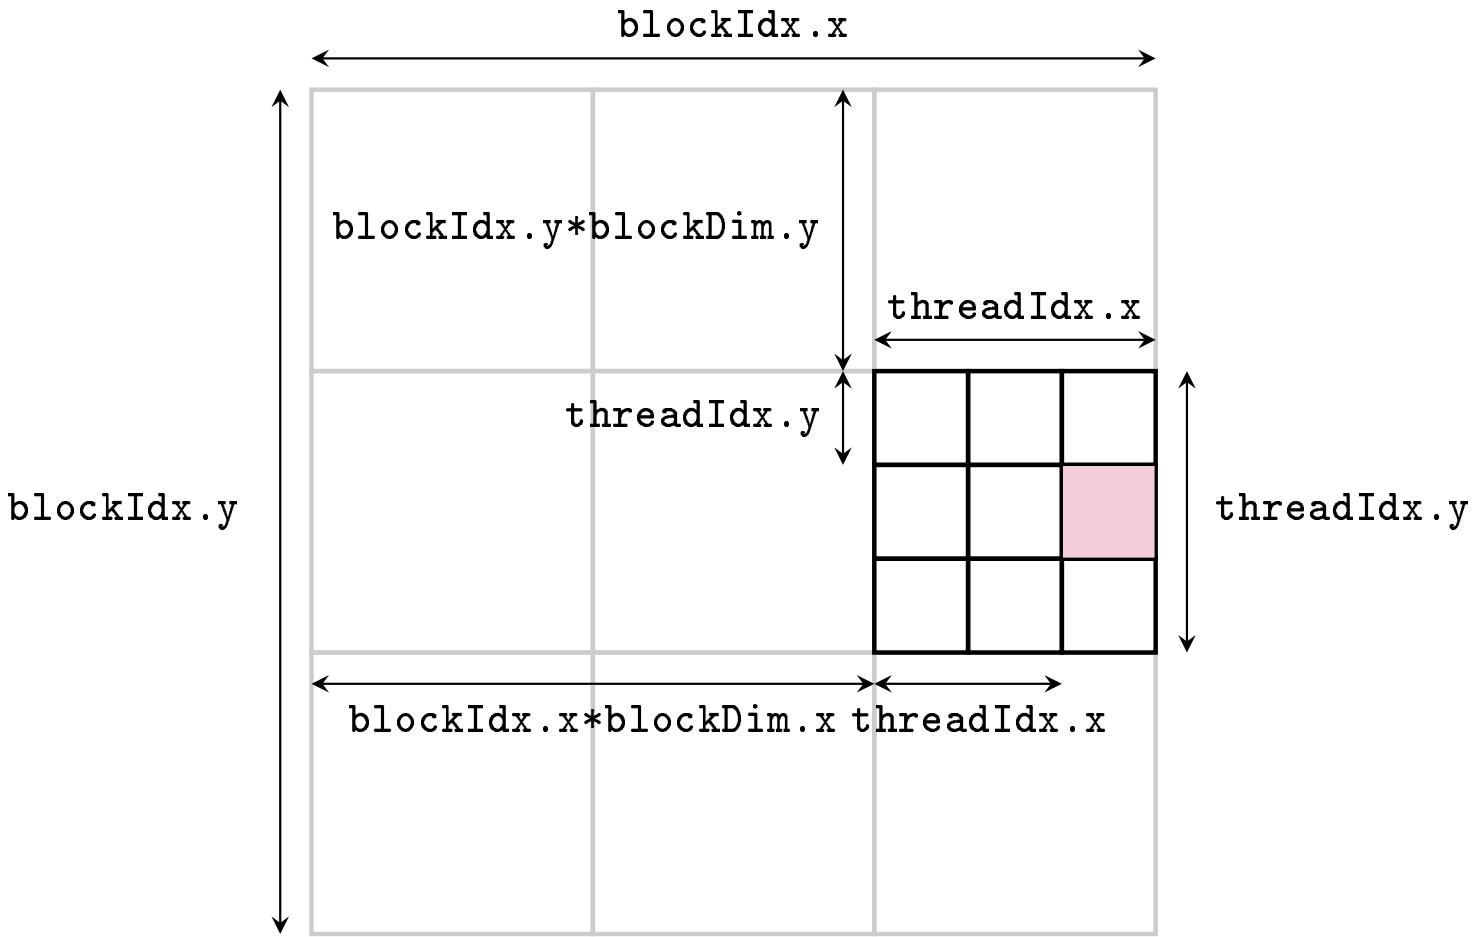

Les indices dans le produit de matrices par tuile : A

- `col = blockIdx.x*blockDim.x+theadIdx.x`
- `ligne = blockIdx.y*blockDim.y+theadIdx.y`
- `TILE_WIDTH = blockDim.x`

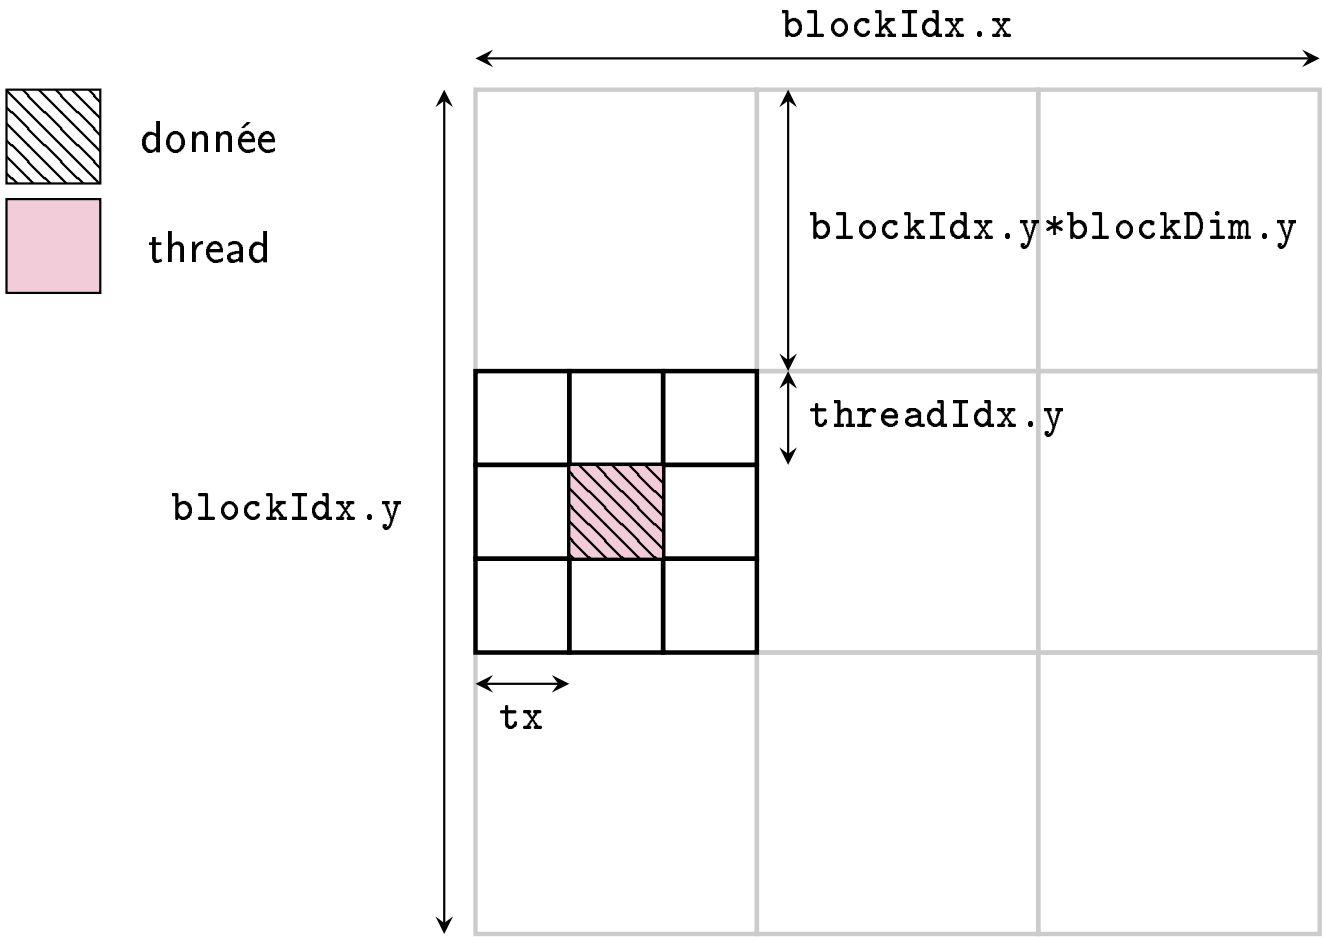

Les indices dans le produit de matrices par tuile : A

- `col = blockIdx.x*blockDim.x+theadIdx.x`
- `ligne = blockIdx.y*blockDim.y+theadIdx.y`
- `TILE_WIDTH = blockDim.x`

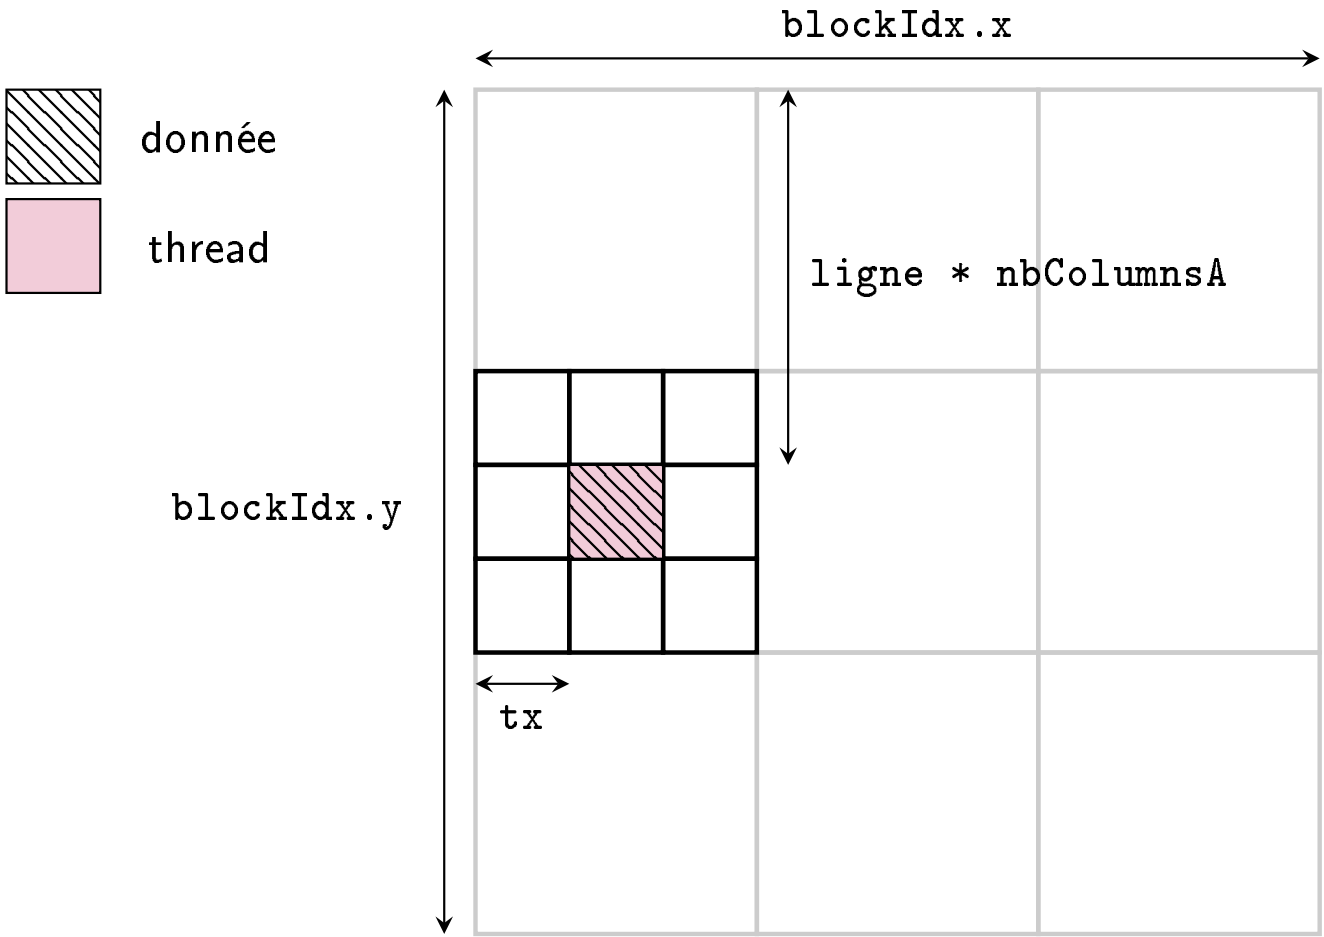

Les indices dans le produit de matrices par tuile : A

- `col = blockIdx.x*blockDim.x+theadIdx.x`
- `ligne = blockIdx.y*blockDim.y+theadIdx.y`
- `TILE_WIDTH = blockDim.x`

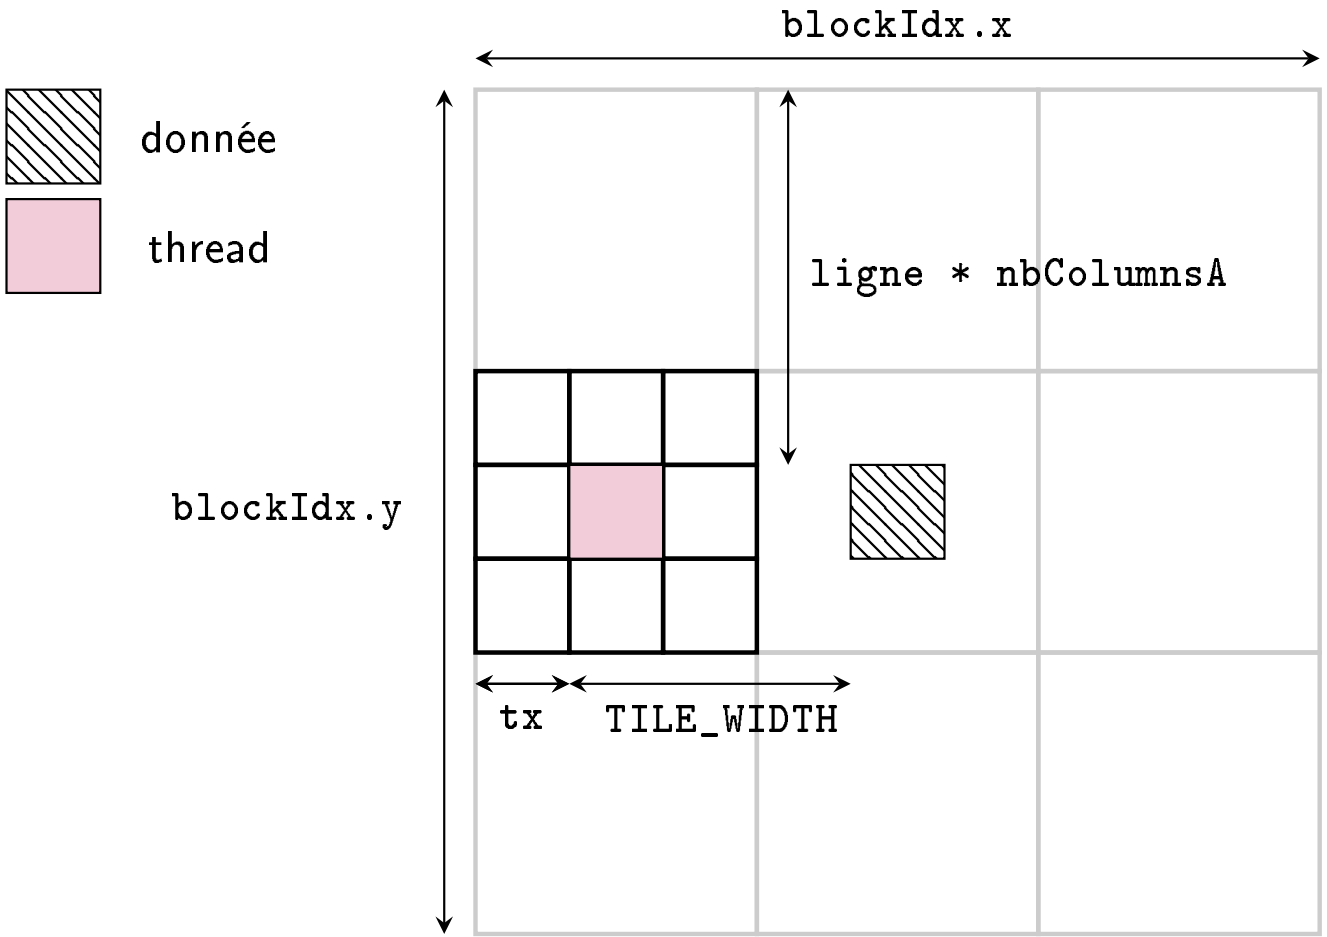

Les indices dans le produit de matrices par tuile : A

- `col = blockIdx.x*blockDim.x+theadIdx.x`
- `ligne = blockIdx.y*blockDim.y+theadIdx.y`
- `TILE_WIDTH = blockDim.x`

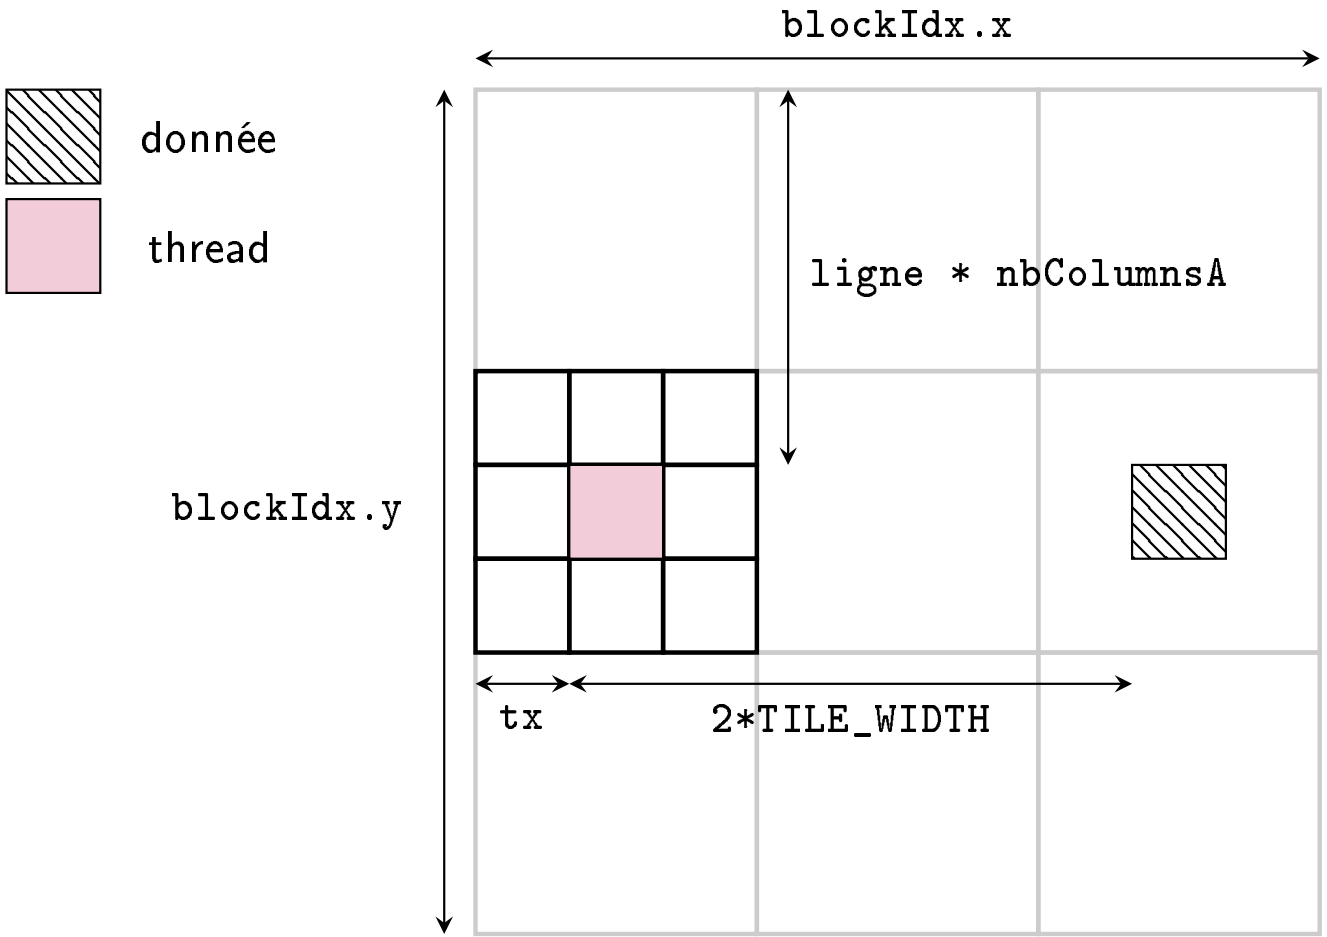

Les indices dans le produit de matrices par tuile : A

- `col = blockIdx.x*blockDim.x+theadIdx.x`
- `ligne = blockIdx.y*blockDim.y+theadIdx.y`
- `TILE_WIDTH = blockDim.x`
- `indice = ligne * nb_colA + TILE_WIDTH * tileId + threadIdx.x`

Les indices dans le produit de matrices par tuile : B

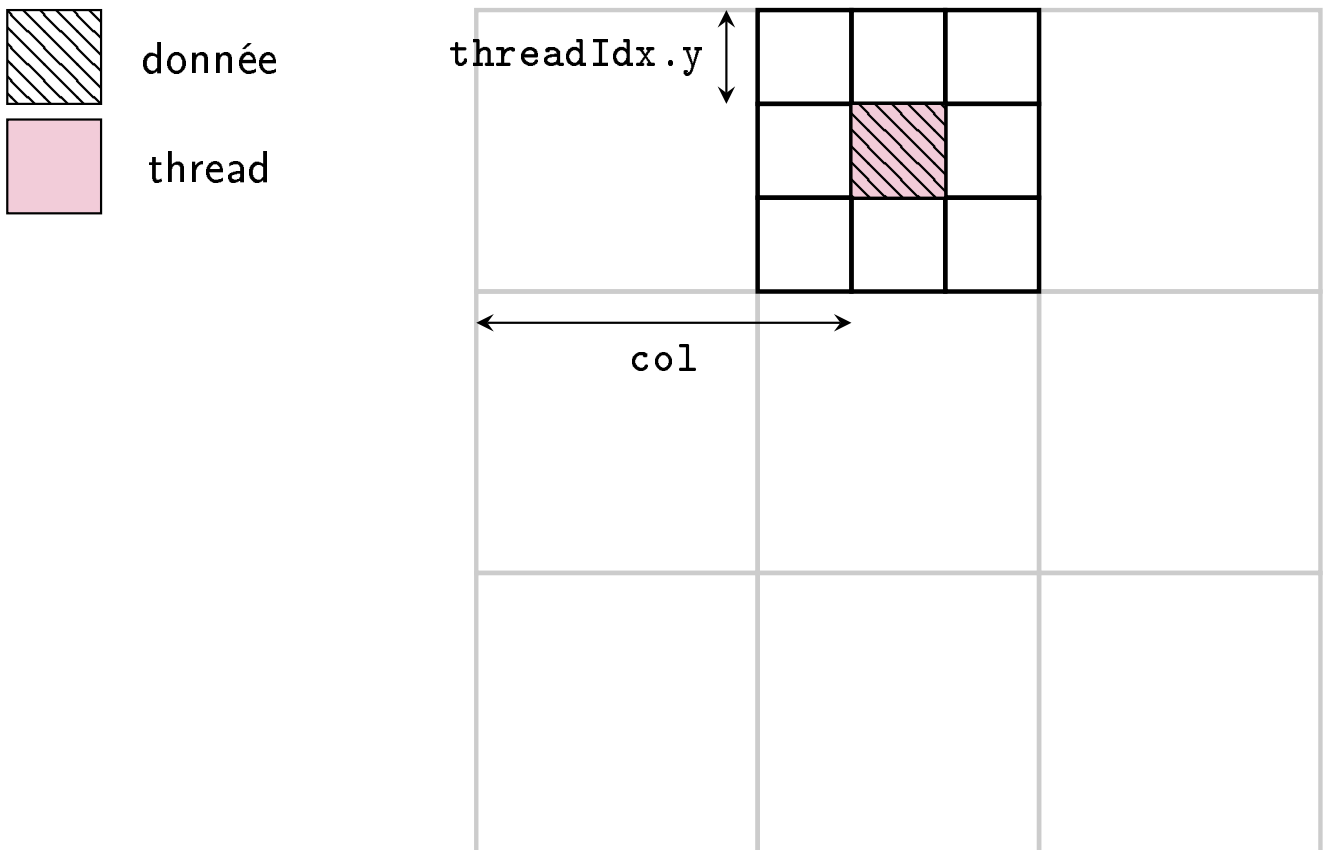

Les indices dans le produit de matrices par tuile : B

- La matrice est stockée par ligne :
  - Les 2 éléments sont séparés par le nombre d'éléments dans une ligne multiplié par la taille de la tuile
  - Une fois dans la bonne tuile, il faut accéder à la bonne ligne, en n'oubliant pas que le stockage est fait par ligne (`ty*nb_col`)

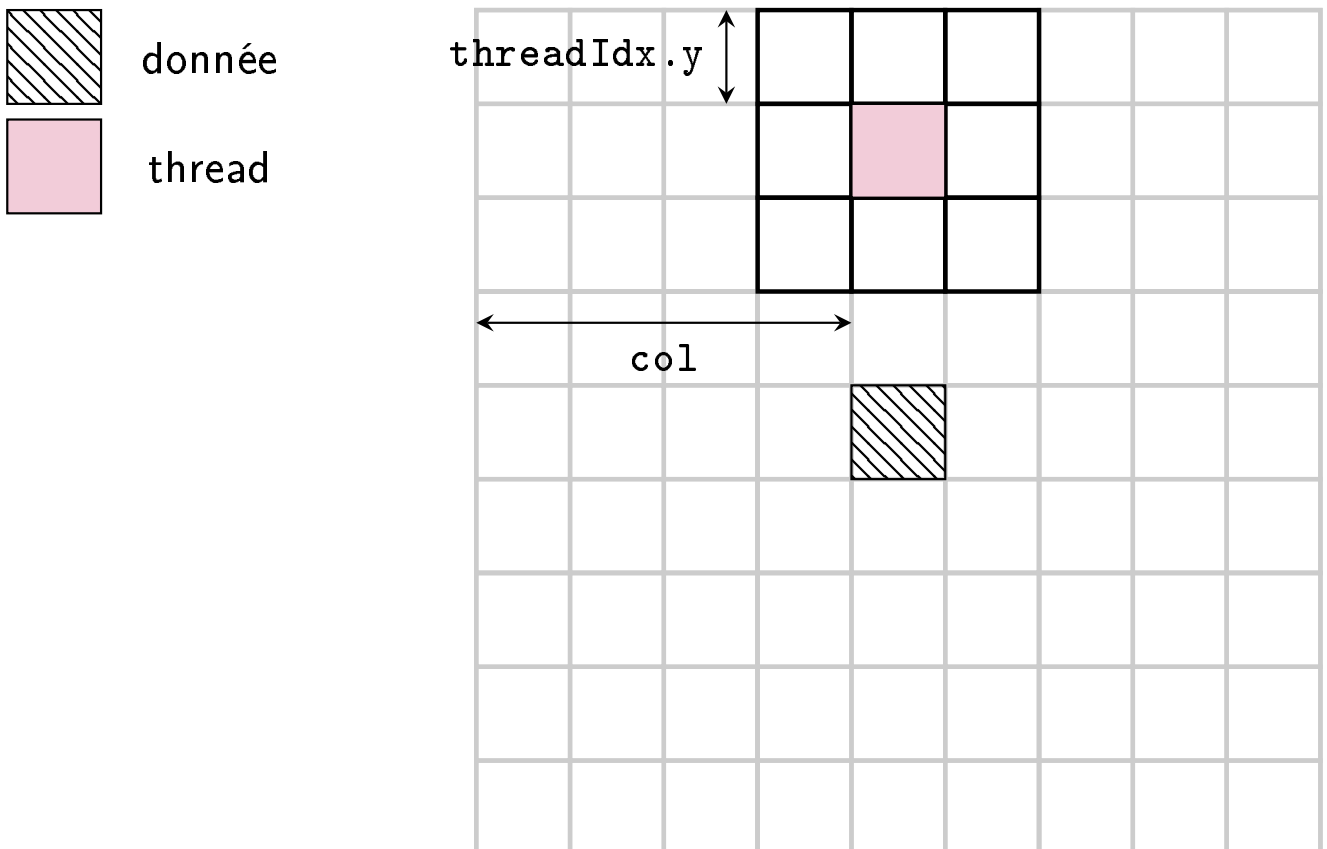

Les indices dans le produit de matrices par tuile : B

- La matrice est stockée par ligne :
  - Les 2 éléments sont séparés par le nombre d'éléments dans une ligne multiplié par la taille de la tuile
  - Une fois dans la bonne tuile, il faut accéder à la bonne ligne, en n'oubliant pas que le stockage est fait par ligne (`ty*nb_col`)

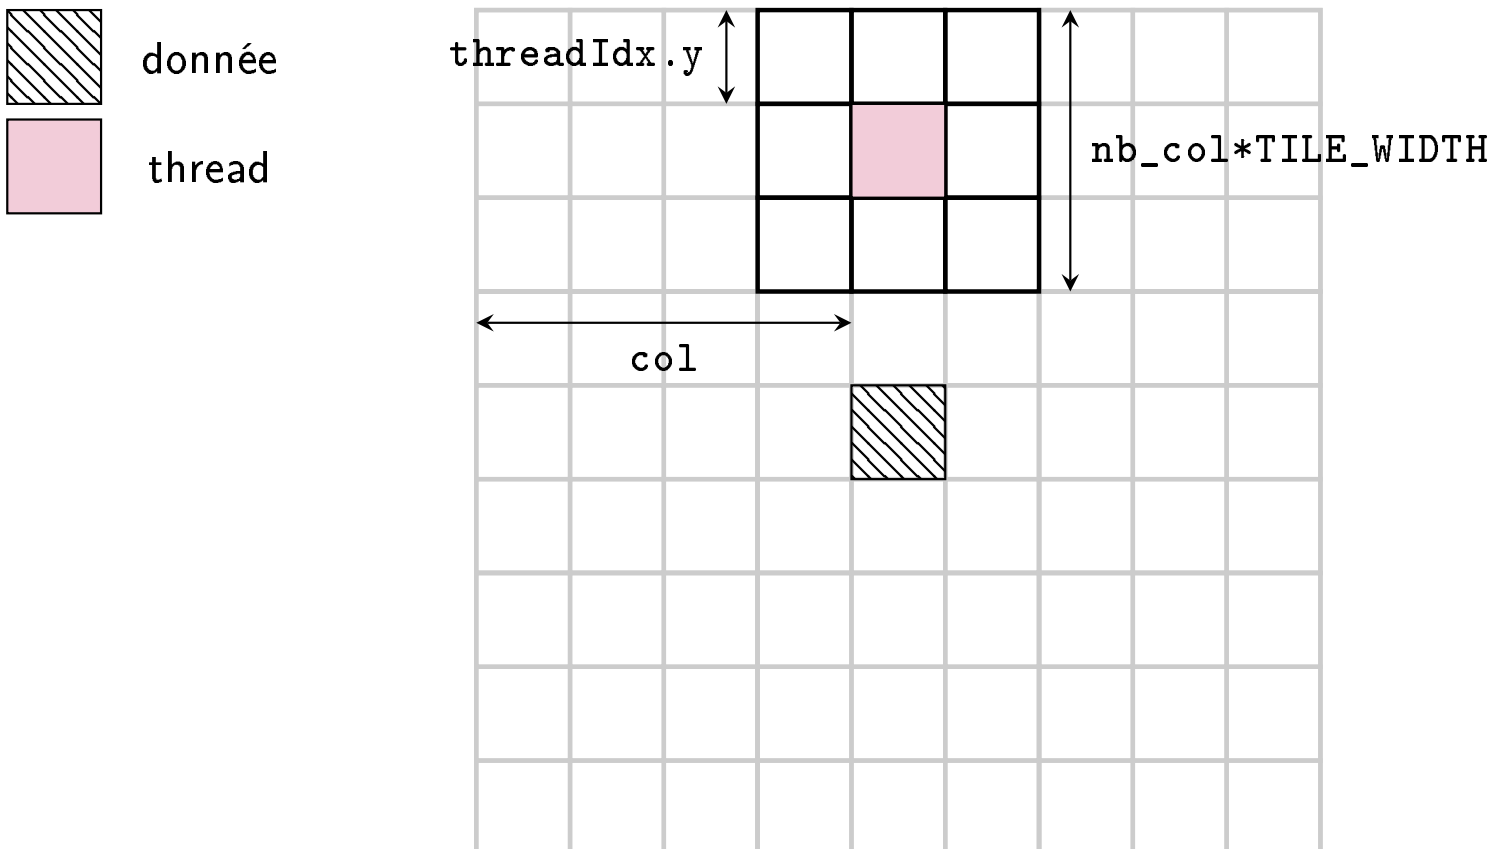

Les indices dans le produit de matrices par tuile : B

- La matrice est stockée par ligne :
  - Les 2 éléments sont séparés par le nombre d'éléments dans une ligne multiplié par la taille de la tuile
  - Une fois dans la bonne tuile, il faut accéder à la bonne ligne, en n'oubliant pas que le stockage est fait par ligne (`ty*nb_col`)

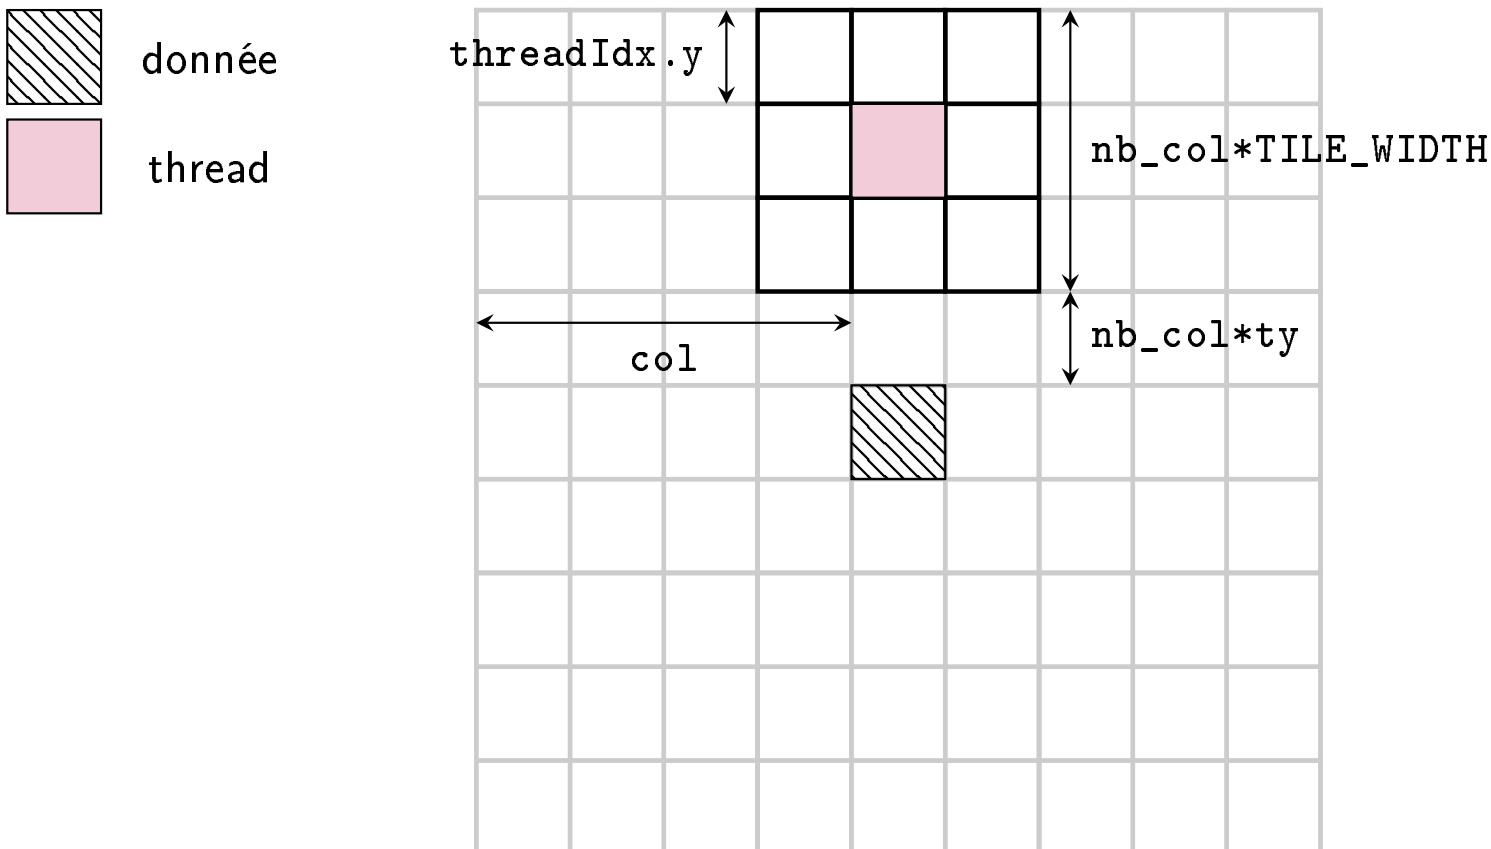

Les indices dans le produit de matrices par tuile : B

- La matrice est stockée par ligne :
  - Les 2 éléments sont séparés par le nombre d'éléments dans une ligne multiplié par la taille de la tuile
  - Une fois dans la bonne tuile, il faut accéder à la bonne ligne, en n'oubliant pas que le stockage est fait par ligne (`ty*nb_col`)

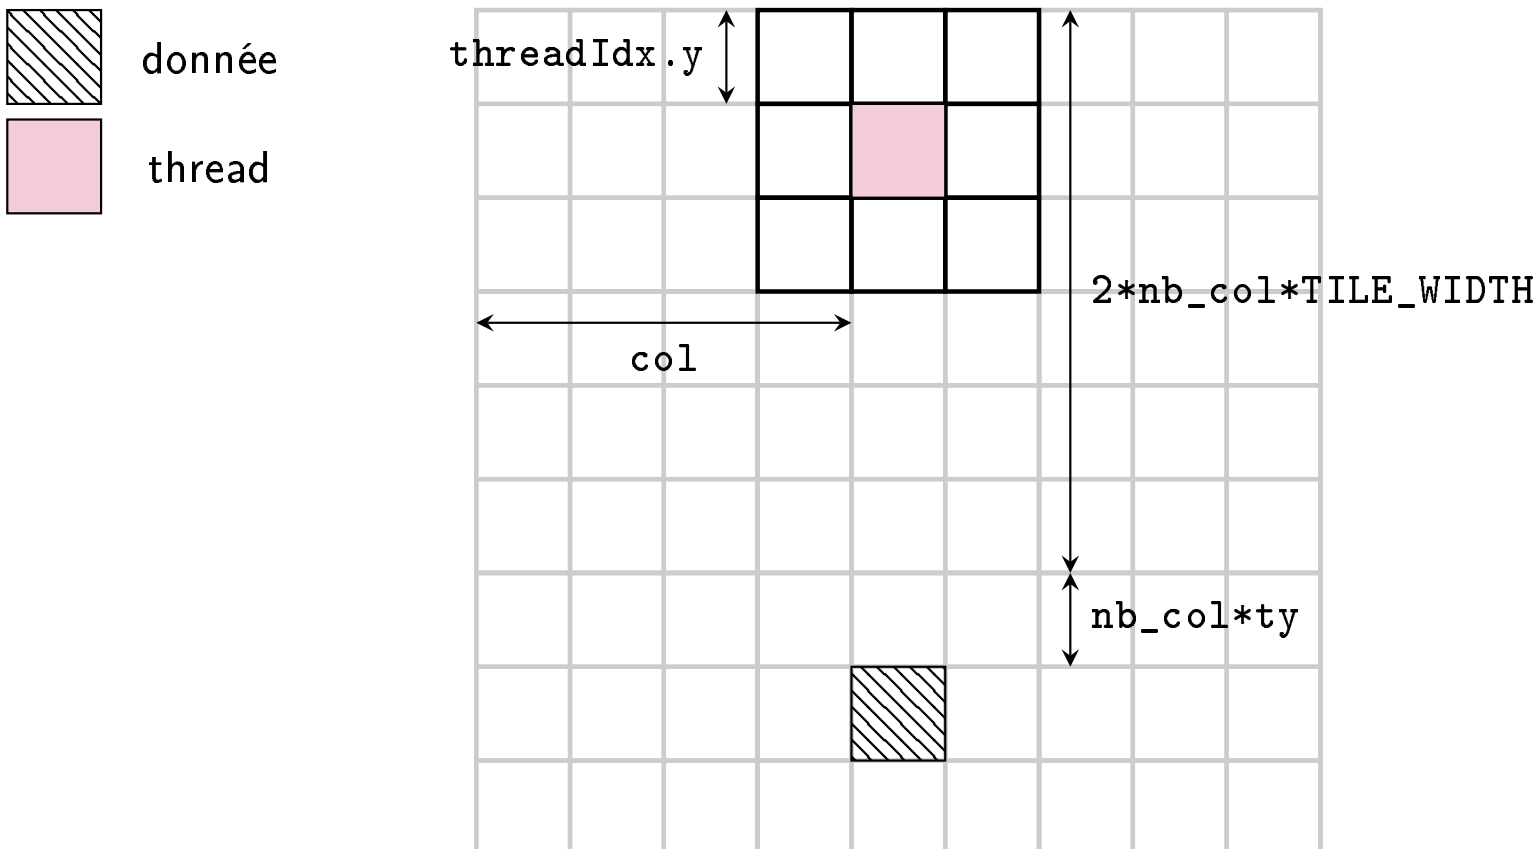

Les indices dans le produit de matrices par tuile : B

- `col = blockIdx.x*blockDim.x+theadIdx.x`
- `ligne = blockIdx.y*blockDim.y+theadIdx.y`
- `TILE_WIDTH = blockDim.x`
- `indice = col + (nb_colB * TILE_WIDTH * tileId + ty * nb_col)`

Les indices dans le produit de matrices par tuile : C

- `col = blockIdx.x*blockDim.x+theadIdx.x`
- `ligne = blockIdx.y*blockDim.y+theadIdx.y`
- `indice = nbCol * ligne + col`